MCDI500

PROGRAMACIÓN PARA LA CIENCIA DE DATOS

EVALUACIÓN SUMATIVA 1 · FASES 1 Y 2

Informe técnico: implementación inicial del entorno reproducible, exploración y procesamiento inicial de los datos

Exposición operacional documentada de las 15 comunas más pobladas de Chile a las fallas del Sistema Eléctrico Nacional (2024–2026)

Programa: Magíster en Ciencia de Datos e Inteligencia Artificial

Grupo: 7

Nombre integrante/s:

Jairo Barraza Salazar
Javier Huamanni Barrera
Jean Salas Meneses
Pavel Chávez San Martín

Curso: MCDI500 · Programación para la Ciencia de Datos

Docente: Dr. Omar Salinas Silva

Repositorio: https://github.com/jeanpaulsalasmeneses-lab/Proyecto_MCDI500

Fecha: 8 de noviembre de 2026

ÍNDICE

II. Introducción y contextualización....6
2.1. Entorno y antecedentes....6
2.2. Situación que origina el análisis....6
2.3. Relevancia del problema....6
2.4. Problema y propósito....7
2.5. Justificación técnica....7
2.6. Conexión con las fases del proyecto....7
III. Definición de la problemática y objetivos....8
3.1. Problemática delimitada....8
3.2. Pregunta analítica....8
3.3. Objetivo general....8
3.4. Objetivos específicos....8
3.5. Alcance....9
3.6. Restricciones....10
3.7. Supuestos....10
3.8. Correspondencia con lo desarrollado en F1 y F2....10
IV. Aplicación de herramientas científicas....12
4.1. Herramientas y propósito en el proyecto....12
4.2. Integración del ecosistema....12
4.3. Reproducibilidad técnica....12
4.4. Control de versiones....13
4.5. Documentación del proceso....14
4.5.1. Flujo de trabajo completo....14
4.5.2. Registro de decisiones técnicas....15
4.5.3. Enfoques descartados....15
4.6. Repositorio GitHub....16
V. Diseño de soluciones algorítmicas eficientes....17
5.1. Codificación funcional....17
5.2. Preprocesamiento y transformación del dataset....18
5.2.1. Diagnóstico previo....18
5.2.2. Roles de las variables y transformación según el rol (D-09)....20
5.2.3. Valores faltantes: patrón, alternativas y decisión (D-05)....21
5.2.4. Valores atípicos (D-08)....21
5.2.5. Normalización y homologación territorial (D-02)....22
5.2.6. Normalización por población (D-06)....22
5.2.7. Conjunto resultante y coherencia con los objetivos....22
5.3. Validación técnica y verificación del código....22
VI. Notebook F1: definición y entorno....24
VII. Notebook F2: exploración y preprocesamiento....25
7.1. Estructura del notebook....25
7.2. Obtención, exploración y limpieza....25
7.3. Resultados intermedios: integración de las 15 comunas prioritarias....25
7.4. Resultados exploratorios....26
7.4.1. Calidad del conjunto de datos....26
7.4.2. Evolución temporal, distribución territorial y consumo....26
7.4.3. Caracterización de instalaciones....28
7.4.4. Clasificación causal....29
7.4.5. Concentración temporal....30
7.4.6. Alcance territorial....31
7.4.7. Distribución por comuna el 25 de febrero de 2025....32
7.4.8. Clasificación del consumo el 25 de febrero de 2025....33

7.4.9. Recurrencia de causas..... 33
7.4.10. Matriz de recurrencia comunal..... 35
7.4.11. Calidad de la información causal por comuna..... 36
7.4.12. Denominador para comparar comunas (D-06)..... 36
7.5. Archivos procesados..... 37
7.6. Conclusiones de la Fase 2..... 37
VIII. Vinculación del mapa conceptual con el avance del proyecto..... 39
IX. Bibliografía..... 42
Anexo A. Declaración de uso de inteligencia artificial..... 43
Anexo B. Detalle de las 40 pruebas automatizadas de F2..... 44
Anexo C. Perfil documental por comuna prioritaria..... 46

ÍNDICE DE FIGURAS

Figura 1. Tipo de dato, valores nulos y porcentaje de nulos de las 40 variables del conjunto consolidado....19
Figura 2. Evolución mensual de informes CEN asociados a las 15 comunas prioritarias (enero de 2024 a septiembre de 2026)....27
Figura 3. Informes del CEN asociados documentalmente a cada comuna prioritaria....27
Figura 4. Composición porcentual de categorías de consumo por comuna prioritaria....28
Figura 5. Tipos de instalación asociados a informes CEN en las 15 comunas prioritarias (2024–2026)....29
Figura 6. Principales descripciones de causas registradas en los informes CEN de las 15 comunas prioritarias....29
Figura 7. Días con mayor concentración de informes CEN en las 15 comunas prioritarias (2024–2026)....30
Figura 8. Cantidad de comunas prioritarias asociadas por informe CEN....31
Figura 9. Informes CEN asociados por comuna prioritaria el 25 de febrero de 2025....32
Figura 10. Clasificación de consumo de los informes CEN del 25 de febrero de 2025....33
Figura 11. Diez descripciones causales más recurrentes en los informes CEN de las 15 comunas prioritarias....34
Figura 12. Principales descripciones con causa definitiva en los informes CEN de las 15 comunas prioritarias....34
Figura 13. Recurrencia documental de las seis principales descripciones causales por comuna prioritaria (porcentaje de asociaciones de cada comuna)....35
Figura 14. Disponibilidad y condición de la información causal en las 15 comunas prioritarias....36
Figura 15. Mapa conceptual del proyecto: exposición operacional documentada de las 15 comunas más pobladas de Chile a fallas del SEN....40

ÍNDICE DE TABLAS

Tabla 1. Aporte y estado de cada fase del proyecto....7
Tabla 2. Objetivos específicos, indicadores de logro, productos verificables y fase....9
Tabla 3. Delimitación temporal de las publicaciones del CEN....10
Tabla 4. Correspondencia entre la formulación y su desarrollo en los notebooks....10
Tabla 5. Herramientas científicas, versión verificada y uso en el proyecto....12
Tabla 6. Evidencias de reproducibilidad técnica y su ubicación....13
Tabla 7. Convención de prefijos de commit....13
Tabla 8. Pull requests del proyecto....14
Tabla 9. Commits por integrante (sin merges)....14
Tabla 10. Flujo de trabajo: entradas, procesos y salidas por etapa....14
Tabla 11. Registro de decisiones técnicas (D-01 a D-09)....15
Tabla 12. Enfoques descartados y motivo....15
Tabla 13. Relación entre el repositorio y los apartados de este informe....16
Tabla 14. Funciones implementadas por componente....17
Tabla 15. Entradas, procesamiento y salidas de funciones representativas....17
Tabla 16. Dimensiones, unicidad y duplicados del conjunto consolidado....19
Tabla 17. Variables con mayor proporción de valores faltantes....20
Tabla 18. Estados administrativos y categorías de consumo normalizados....20
Tabla 19. Presencia de fecha efectiva de término según estado administrativo (base completa)....21
Tabla 20. Alternativas evaluadas para la fecha de término faltante....21
Tabla 21. Efecto de los tratamientos de atípicos sobre la duración documental (15 comunas, finalizados)....21
Tabla 22. Pasos de la homologación territorial CEN–INE....22
Tabla 23. Pruebas funcionales iniciales de F1....22
Tabla 24. Pruebas automatizadas de F2 por grupo de validación....23
Tabla 25. Estructura del notebook F1 y correspondencia con el proyecto....24
Tabla 26. Resultados del diagnóstico de factibilidad comunal de F1....24
Tabla 27. Etapas del notebook F2 y secciones correspondientes....25
Tabla 28. Comunas prioritarias: población censada e informes asociados....25
Tabla 29. Condición de la información causal en los informes prioritarios....30
Tabla 30. Conteo y tasa documental por 100.000 habitantes-año por comuna (propuesta D-06)....36
Tabla 31. Conjuntos exportados por F2 en la carpeta data/processed/f2/....37

Tabla 32. Correspondencia entre los elementos del mapa conceptual y su implementación.....39
Tabla 33. Pruebas automatizadas de F2: grupo, prueba, resultado y observación.....44
Tabla 34. Perfil documental por comuna: instalación, causa, consumo y 25 de febrero de 2025.....46

II. INTRODUCCIÓN Y CONTEXTUALIZACIÓN

2.1. Entorno y antecedentes

El Sistema Eléctrico Nacional (SEN) abastece a la mayor parte de la población de Chile. El Coordinador Eléctrico Nacional (CEN) coordina su operación y publica cada mes los informes de falla de las instalaciones de generación y transmisión, dentro del conjunto *Desconexiones e intervenciones / informes de falla / limitaciones* (Coordinador Eléctrico Nacional [CEN], s. f.). Cada informe identifica la instalación, la causa declarada, las fechas de perturbación y término, el consumo reportado como afectado y, en el campo `Comuna`, uno o más territorios mencionados.

Este proyecto usa las 33 publicaciones mensuales de enero de 2024 a septiembre de 2026, que suman 18.019 informes y 28 variables originales, y la tabla oficial de población comunal del Censo 2024 (Instituto Nacional de Estadísticas [INE], 2025).

2.2. Situación que origina el análisis

Las comparaciones territoriales de calidad de suministro en Chile usan indicadores regulatorios como SAIDI y SAIFI. Estos se calculan con clientes interrumpidos y tiempos efectivos de interrupción (Comisión Nacional de Energía [CNE], 2024; Superintendencia de Electricidad y Combustibles [SEC], s. f.). Los informes del CEN describen otra cosa: fallas de instalaciones del sistema, sin número de clientes. Hoy no existe una vista comunal y reproducible de esos informes, por cuatro razones:

- la información está repartida en 33 archivos comprimidos;
- la comuna viene como texto libre;
- un mismo informe puede mencionar varias comunas separadas por «|»;
- los nombres no coinciden siempre con los nombres oficiales del INE.

2.3. Relevancia del problema

La continuidad del suministro eléctrico condiciona el funcionamiento de hogares, servicios públicos, establecimientos de salud, actividades productivas y otras funciones territoriales. Por ello, el estudio de las fallas del SEN adquiere una dimensión adicional cuando se pregunta dónde se registra la afectación del consumo y qué comunas presentan una mayor exposición documental a estos eventos (F1 §1).

La Norma Técnica de Calidad de Servicio para Sistemas de Distribución distingue la frecuencia y la duración de las interrupciones efectivamente experimentadas por los clientes (CNE, 2024). Este marco obliga a diferenciar **una falla o indisponibilidad de instalaciones del SEN** de **una interrupción de suministro comprobada para usuarios de una comuna**: no son magnitudes equivalentes (F1 §1 y §4.1). El enfoque de Silva et al. (2025), basado en registros de fallas de distribución eléctrica, respalda la utilidad de examinar conjuntamente recurrencia, causas y localización; como su sistema de estudio es distinto del SEN chileno, sus hallazgos no se extrapolan y solo se aprovecha su fundamento metodológico (F1 §4.3).

2.4. Problema y propósito

El problema es medir y comparar la **exposición operacional documentada** de las 15 comunas más pobladas de Chile a las fallas del SEN. Definimos esa exposición como la frecuencia, la recurrencia y la duración de los informes de falla del CEN que mencionan a cada comuna. No equivale a interrupciones efectivas de suministro, porque que un informe mencione una comuna no prueba que sus clientes quedaran sin luz.

Este informe documenta el avance de las Fases 1 y 2: la definición del problema, el entorno reproducible y el pipeline de obtención, exploración, limpieza, transformación y validación de los datos. Cada cifra que aparece aquí se puede verificar en los notebooks F1 y F2 y en el repositorio.

2.5. Justificación técnica

El problema requiere programación por cinco razones:

- **Volumen y dispersión:** 33 archivos que hay que leer, validar y consolidar con trazabilidad hasta la fila de origen.
- **Normalización textual:** 320 denominaciones comunales distintas que deben homologarse con los 346 códigos oficiales del INE.
- **Relación muchos a muchos:** 16.874 informes con comuna generan 23.284 vínculos informe–comuna.
- **Validación sistemática:** 40 pruebas automatizadas en F2 y verificaciones de integridad en cada etapa.
- **Reproducibilidad:** otro equipo debe poder repetir todo el proceso y obtener los mismos archivos. En hojas de cálculo eso no se puede garantizar.

2.6. Conexión con las fases del proyecto

Tabla 1. *Aporte y estado de cada fase del proyecto*

Fase	Aporte al proyecto	Estado
F1. Definición y entorno	Problema, pregunta, objetivos, alcance, entorno reproducible y mapa conceptual	Desarrollada (este informe)
F2. Exploración y preprocesamiento	Obtención, diagnóstico de calidad, limpieza, homologación CEN–INE, transformación y validación	Desarrollada (este informe)
F3. Análisis	Indicadores comunales: tasa de exposición, recurrencia, duración y consumo reportado	Proyectada
F4. Visualización y comunicación	Visualizaciones comparativas, hallazgos, conclusiones y recomendaciones	Proyectada

Fuente: Elaboración propia a partir de F1 §5.4 (articulación con las fases F1–F4).

III. DEFINICIÓN DE LA PROBLEMÁTICA Y OBJETIVOS

3.1. Problemática delimitada

Se analiza cómo se distribuyen los informes de falla del SEN publicados por el CEN entre enero de 2024 y septiembre de 2026 entre las 15 comunas más pobladas de Chile, según el Censo 2024. La unidad de registro es el informe de falla (`id_falla`), y la unidad de comparación es la comuna. La relación entre ambas es el vínculo informe–comuna: un informe que menciona tres comunas genera tres vínculos, pero sigue siendo un solo informe.

Tal como se formuló en F1 §2, el problema no consiste solamente en contar fallas: *consiste en establecer una metodología verificable para vincular los eventos documentados con las comunas mencionadas, identificar cuándo se reporta afectación del consumo y comparar territorialmente la exposición a esos eventos sin confundirla con la duración real de los cortes sufridos por los usuarios.*

En este proyecto, «comunas prioritarias» designa exclusivamente a las 15 comunas con mayor población censada en el Censo 2024. El término no implica un criterio de vulnerabilidad, criticidad ni prioridad de política pública (F1 §1).

3.2. Pregunta analítica

> *¿Cómo se distribuye la exposición operacional documentada a fallas del Sistema Eléctrico Nacional entre las 15 comunas más pobladas de Chile (Censo 2024), entre enero de 2024 y septiembre de 2026, medida como la frecuencia de informes del CEN en relación con su población, la recurrencia temporal y la duración documental de esos informes, y qué parte de esa exposición corresponde a eventos con afectación de consumo reportada?*

Preguntas complementarias (F1 §3): ¿qué proporción de los informes menciona comunas identificables?, ¿qué categorías de consumo se reportan?, ¿qué tipos de instalaciones y causas están asociadas a los eventos?, ¿cuánto cambia el resultado cuando se restringe el análisis a registros técnicamente válidos?, ¿qué información adicional sería necesaria para medir SAIDI, SAIFI o clientes-hora interrumpidos por comuna?

3.3. Objetivo general

El objetivo general se transcribe con la redacción registrada en F1 §5.1:

> **Analizar comparativamente la exposición operacional documentada a eventos de falla del Sistema Eléctrico Nacional en las 15 comunas de mayor población censada de Chile, considerando los informes publicados entre enero de 2024 y septiembre de 2026, mediante procedimientos reproducibles de ciencia de datos que permitan caracterizar la frecuencia, recurrencia, afectación de consumo reportada y duración documental válida de los eventos, con resultados y límites de interpretación claramente identificados.**

3.4. Objetivos específicos

Los objetivos específicos se transcriben con la redacción registrada en F1 §5.2:

OE1. Integrar las fuentes documentales y territoriales del estudio. Integrar las 33 publicaciones mensuales de informes de falla del CEN con una tabla oficial del Censo 2024 del INE, conservando identificadores, procedencia y variables originales, durante la preparación inicial y F2.

OE2. Depurar y vincular los registros con las comunas. Depurar los 18.019 registros iniciales y normalizar los campos `Comuna`, `Consumo`, `Estado` y fechas, resolviendo listas multicomuna y validando la correspondencia con códigos comunales oficiales, para obtener un conjunto territorial trazable al cierre de F2.

OE3. Seleccionar y caracterizar las comunas prioritarias. Seleccionar las 15 comunas de mayor población censada nacional en 2024 y caracterizar la cobertura, completitud y composición de informes asociados a cada una, utilizando criterios reproducibles al término de F2 y el análisis inicial de F3.

OE4. Cuantificar los antecedentes de exposición operacional documentada. Cuantificar, para cada comuna seleccionada, al menos cuatro dimensiones: informes únicos asociados, informes con consumo afectado reportado, recurrencia temporal y duración documental válida, utilizando criterios explícitos de inclusión en F3.

OE5. Visualizar, contrastar y comunicar los resultados territoriales y sus límites de medición. Construir al menos cuatro visualizaciones comparativas de la distribución comunal, temporal, técnica y por categoría de consumo, incorporando tasas de cobertura e incertidumbres de registro (F3–F4). A partir de ellas, presentar al menos cinco hallazgos, tres conclusiones y dos recomendaciones basadas en evidencia, que distingan la exposición documental, la interrupción efectiva del suministro y los indicadores regulatorios que requieren información adicional (cierre de F4).

Tabla 2. *Objetivos específicos, indicadores de logro, productos verificables y fase*

Objetivo	Indicador de logro	Producto verificable	Fase
OE1. Integración CEN–INE	33 de 33 meses consolidados; 346 comunas INE con código único	Inventario de 33 publicaciones y fuente censal documentada	F1–F2
OE2. Calidad y enlace territorial	Porcentaje de vínculos homologados con el INE (logrado: 100 %)	Tabla de informes y tabla de relación informe–comuna; reporte de validación	F2
OE3. Selección reproducible	Lista reproducible de 15 comunas; informes y vínculos asociados (1.834 y 1.915)	Lista de 15 comunas, población y cobertura documental	F2–F3
OE4. Exposición operacional	Cuatro dimensiones por comuna, con criterios de inclusión explícitos	Indicadores comunales con denominador, exclusiones y limitaciones	F3
OE5. Comparación y comunicación	Al menos 4 visualizaciones, 5 hallazgos, 3 conclusiones y 2 recomendaciones	Visualizaciones con interpretación cautelosa; hallazgos, conclusiones y recomendaciones verificables	F3–F4

Fuente: Elaboración propia a partir del informe de avance del Grupo 7 (indicadores de logro) y de F1 §5.3 (productos verificables y fase).

3.5. Alcance

Son decisiones del equipo:

- **Se aborda:**
  - las 15 comunas con mayor población censada en 2024, sin importar a qué región pertenezcan;
  - los informes de falla del CEN publicados entre enero de 2024 y septiembre de 2026;
  - indicadores descriptivos de exposición documental.
- **Queda fuera:**
  - indicadores regulatorios (SAIDI, SAIFI, clientes-hora interrumpidos);
  - energía no suministrada y pérdidas económicas;
  - modelos predictivos;
  - las solicitudes de trabajo y las limitaciones, que vienen en los mismos ZIP del CEN pero no son

informes de falla;

– el resto de las 331 comunas, salvo como contexto.

Delimitación temporal y unidad de análisis (F1 §6.1–§6.2). Se mantienen dos niveles de observación: el informe de falla (unidad base de trazabilidad) y el vínculo informe–comuna. La unidad de comparación del resultado es la comuna. Se distinguen año y mes de publicación y fecha de ocurrencia:

Tabla 3. *Delimitación temporal de las publicaciones del CEN*

Año de publicaciones	Meses	Regla de comparación
2024	12	Año completo o enero–septiembre para comparación homogénea
2025	12	Año completo o enero–septiembre para comparación homogénea
2026	9	Solo enero–septiembre

Fuente: Elaboración propia a partir de F1 §6.2.

3.6. Restricciones

Son condiciones impuestas por los datos, el tiempo o las herramientas:

- **Datos:** los informes no incluyen el número de clientes afectados. El 40,04 % no tiene fecha efectiva de término, y el 6,35 % no tiene comuna. Las causas vienen parcialmente en texto libre, y el 60,47 % de los informes prioritarios no tiene una causa determinada.
- **Cobertura temporal:** 2026 tiene solo 9 meses publicados, así que las comparaciones anuales deben normalizarse por tiempo observado.
- **Tiempo:** el proyecto se desarrolla en tres semanas; esta entrega corresponde a la primera.
- **Herramientas:** se usa el ecosistema del curso (Python 3.13, pandas, NumPy, matplotlib, Jupyter, Git y GitHub). No se usan sistemas de información geográfica.

3.7. Supuestos

1. Una mención de comuna en un informe del CEN indica exposición documental de esa comuna, no una interrupción de sus clientes.
2. Los nombres de comuna del CEN se pueden homologar con el INE cuando la correspondencia es unívoca y la región declarada en `Zona Afectada` coincide.
3. La población censada es un normalizador territorial válido para comparar comunas de distinto tamaño (D-06). No mide clientes, consumo ni infraestructura.
4. La fecha efectiva de término marca el cierre administrativo del informe, no necesariamente la reposición del suministro a cada cliente.
5. El conjunto publicado por el CEN es la fuente oficial disponible. Su completitud no se puede auditar contra otra fuente.

3.8. Correspondencia con lo desarrollado en F1 y F2

Tabla 4. *Correspondencia entre la formulación y su desarrollo en los notebooks*

Elemento de la formulación	Dónde se desarrolla
Problema, pregunta, objetivos, alcance y supuestos	F1 §1–§6
OE1: integración CEN–INE	`src/descargar_cen.py`, `src/consolidar_fallas_2024_2026.py`, F2 §6.5
OE2: depuración y homologación	F2 §4–§6.7 y `data/reference/`
OE3: selección y cobertura de las 15 comunas	F2 §6.5.2 y §6.8

Elemento de la formulación	Dónde se desarrolla
OE4 y OE5: indicadores y comunicación	Propuestas en F2 §6.10.5, §6.10.6 y §6.13.7; se calculan en F3 y F4

Fuente: Elaboración propia a partir de los notebooks F1 y F2.

IV. APLICACIÓN DE HERRAMIENTAS CIENTÍFICAS

4.1. Herramientas y propósito en el proyecto

Cada herramienta resuelve un problema concreto del proyecto. La versión de cada biblioteca corresponde a la registrada por la verificación del entorno de F1 §8.1 y F2 §0:

Tabla 5. *Herramientas científicas, versión verificada y uso en el proyecto*

Herramienta	Versión verificada	Propósito en este proyecto	Dónde se usa
Python	3.13.12	Lenguaje del pipeline completo; módulos en `src/`	F1, F2, `src/`
pandas	3.1.0	Leer CSV y Excel, normalizar, cruzar tablas (`merge` con `validate`), agrupar y exportar	F1 §8.2; F2 en todas las etapas; `src/`
NumPy	2.5.4	Base numérica de pandas y valores faltantes (`np.nan`); semilla aleatoria	F2 y `src/trazabilidad.py`
matplotlib	3.11.2	Mapa conceptual y figuras exploratorias guardadas en `F2/figuras/`	F1 §9 y F2 §6.11–§6.13
Jupyter (ipykernel)	7.4.0	Notebooks con código, salidas y narrativa, uno por fase	`F1/`, `F2/`
openpyxl	3.1.5	Lectura del Excel oficial del Censo 2024	F2 §6.5
Git y GitHub	—	Versionar cada cambio, revisar por pull request y registrar decisiones en issues	Historial del repositorio
venv y requirements.txt	106 de 106 coinciden (Linux)	Aislar el entorno y fijar las versiones exactas	`.venv/`, `requirements.txt`

Fuente: Elaboración propia a partir de las salidas de verificación del entorno de F1 §8.1–§8.1.1 (ejecuciones 1 y 2) y F2 §0 (ejecución 1).

Las librerías se usan dentro de funciones, no en celdas sueltas. Algunos ejemplos son `normalizar_comuna()`, `auditar_asociacion()`, `comparar_alternativas()` y `perfil_variable()` en F2, y `verificar_dataset()` en F1.

4.2. Integración del ecosistema

La integración del ecosistema se ve en tres señales:

1. Verificación del entorno al inicio de cada notebook (F1 §8.1 y §8.1.1, F2 §0).
2. Rutas relativas, porque la raíz del proyecto se ubica automáticamente (`localizar_proyecto()` en F1 y F2).
3. Commit y rama en que se ejecutó cada notebook, impresos por `src/trazabilidad.py`.

4.3. Reproducibilidad técnica

- **Entorno virtual:** `.venv` creado con `venv`, de la biblioteca estándar de Python (Python Software Foundation, s. f.). Los notebooks fallan a propósito si el kernel no es el del entorno virtual.
- **Dependencias:** `requirements.txt` fija 107 paquetes con versión exacta. `pywinpty` lleva el marcador `sys_platform == "win32"` y solo se instala en Windows.
- **Verificación componente por componente:** `src/trazabilidad.py` compara cada dependencia declarada con la instalada y detiene el notebook si alguna no coincide. En Linux el resultado es 106 de 106 (107 en Windows).
- **Rutas relativas y semilla:** no hay rutas absolutas en el código. La semilla está fija en 2024, aunque el pipeline no usa procesos aleatorios.

- **Integridad de las salidas:** siguiendo prácticas de computación científica reproducible (Wilson et al., 2017), F2 exporta siete archivos con su SHA-256 en `data/processed/f2/manifest_f2.json` y comprueba que coincidan (§6.15.5). Se agregó `.gitattributes` (`*.csv -text`) porque Git en Windows cambiaba los saltos de línea de los CSV al hacer commit, y eso rompía los hashes en otro equipo (D-04).

La salida de verificación registrada en F2 §0 (ejecución 1) deja constancia del entorno con que se produjeron los resultados:

```
============================================================
VERIFICACIÓN DEL ENTORNO Y TRAZABILIDAD DE LA EJECUCIÓN
============================================================
Python 3.13.12 · Linux 7.2.13-200.fc44.x86_64
Entorno virtual activo: sí
Raíz del proyecto: Proyecto_MCDI500/ (rutas relativas a esta carpeta)
Commit: d8b597b · rama: feat/rubrica-sumativa · cambios sin commit: sí
Semilla aleatoria: 2024 (el pipeline no usa procesos aleatorios)

Dependencias de requirements.txt verificadas: 106 de 106 coinciden con la versión declarada
[OK] Entorno verificado componente por componente.
```

Comprobación en un segundo equipo. La verificación está registrada en `docs/verificacion_entorno.md` y resumida en F2 §6.16.7:

- Se clonó el repositorio en una carpeta limpia de Linux (Python 3.13), sin los datos originales, y se ejecutaron F1 y F2 completos sin errores. Los 7 de 7 archivos exportados resultaron idénticos byte a byte.
- Los consolidados también se reconstruyeron desde la fuente original: se descargaron de nuevo los 33 ZIP con `src/descargar_cen.py`, se ejecutó la consolidación y el contenido resultó idéntico (18.019 registros, ninguna celda distinta).
- El mismo procedimiento quedó documentado para la verificación en Windows.

Tabla 6. *Evidencias de reproducibilidad técnica y su ubicación*

Verificación	Resultado registrado	Evidencia
Entorno virtual activo	Sí	F1 §8.1 (ejec. 1); F2 §0 (ejec. 1)
Versiones de dependencias	106 de 106 coinciden con `requirements.txt`	F1 §8.1.1 (ejec. 2); F2 §0
Rutas	Relativas a la raíz `Proyecto_MCDI500/`	`localizar_proyecto()` en F1 y F2
Semilla	2024 (sin procesos aleatorios)	F1 §8.1.1; F2 §0
Ejecución completa	F1: ejecuciones 1–5; F2: ejecuciones 1–28, continuas y sin errores	Notebooks entregados con salidas
Integridad de archivos	7 de 7 CSV con SHA-256 coincidente	F2 §6.15.5 (ejec. 28); `manifest_f2.json`
Segundo entorno	Clon limpio en Linux; F1 y F2 completos; hashes idénticos	`docs/verificacion_entorno.md`; F2 §6.16.7

Fuente: Elaboración propia a partir de las salidas de los notebooks F1 y F2 y de la documentación del repositorio.

4.4. Control de versiones

Convención de commits. Prefijo y descripción en español:

Tabla 7. *Convención de prefijos de commit*

Prefijo	Uso
`feat:`	Funcionalidad o análisis nuevo
`fix:`	Corrección
`docs:`	Documentación

Prefijo	Uso
`data:`	Cambios en los datos
`build:`	Entorno y dependencias
`merge:`	Integración de ramas

Fuente: Elaboración propia a partir del historial del repositorio del proyecto.

Los mensajes explican qué cambió y por qué, y citan el issue o el criterio de la rúbrica que resuelven (Chacon y Straub, 2014).

Ramas y pull requests. Los cambios de mayor alcance se integraron mediante pull request. Las salidas de F1 y F2 registran que los notebooks se ejecutaron en la rama `feat/rubrica-sumativa` (commit `d8b597b`).

Tabla 8. *Pull requests del proyecto*

PR	Contenido
#2	Ajuste del texto del problema
#3	Reproducibilidad: datos, `.gitignore` y dependencias
#4–#6	Mapa conceptual y entrega de la Formativa
#14	Correcciones del feedback de la Formativa
Este avance	Brechas de la rúbrica de la Sumativa

Fuente: Elaboración propia a partir del historial del repositorio del proyecto.

Issues. El feedback docente de la Formativa se convirtió en seis issues (#8–#13), uno por punto, que los commits cierran con `Closes #n`. La propuesta de selección de columnas de Jairo Barraza se registró como issue #7 y se concilió en F2 §4.5.

Contribuciones por integrante. Commits identificables en el historial al momento de generar el informe de avance (commit `bc2541b`):

Tabla 9. *Commits por integrante (sin merges)*

Integrante	Commits (sin merges)
Jairo Barraza Salazar	12
Javier Huamanni Barrera	0
Jean Salas Meneses	22
Pavel Chávez San Martín	23
Total	**57**

Fuente: Elaboración propia a partir del historial de commits del repositorio (commit `bc2541b`).

Mejora pendiente. Parte del desarrollo de F2 se subió directamente a la rama principal, sin pull request. Desde la Fase 3, todo cambio entra por PR con revisión de otro integrante.

4.5. Documentación del proceso

4.5.1. Flujo de trabajo completo

Tabla 10. *Flujo de trabajo: entradas, procesos y salidas por etapa*

Etapa	Entrada	Proceso	Salida
0. Obtención	Portal del CEN y Censo 2024	`src/descargar_cen.py` descarga y verifica los 33 ZIP; el Excel del INE se descarga con su SHA-256	`data/raw/*.zip`, `docs/descargas_cen.csv`, `data/external/`
1. Consolidación	33 ZIP	`src/consolidar_fallas_2024_2026.py`: lee solo el informe de fallas y agrega trazabilidad (ZIP, CSV, fila)	`data/processed/cen_fallas_2024_2026_{publicaciones,eventos}.csv`

Etapa	Entrada	Proceso	Salida
2. Definición	Consolidado	F1: verificación estructural sin transformar, pruebas iniciales y mapa	Diagnóstico de factibilidad y mapa
3. Exploración y calidad	Consolidado	F2 §0–§4: dimensiones, tipos, nulos, duplicados y roles	Diagnóstico y `docs/diccionario_variables.csv`
4. Limpieza y normalización	Consolidado	F2 §5: claves de comuna, separación de listas, estados y consumo	23.284 vínculos informe–comuna
5. Homologación	Vínculos e INE	F2 §6.5–§6.7: maestro de 346 comunas y equivalencias de `data/reference/`	100 % homologado; `data/processed/homologacion/`
6. Transformación	Vínculos homologados	F2 §6.8–§6.10: 15 comunas, variables operacionales y temporales, faltantes y atípicos	Informes y vínculos prioritarios
7. Caracterización	Conjunto prioritario	F2 §6.11–§6.13: visualizaciones, causas y denominador	Perfiles comunales y figuras
8. Validación y exportación	Todo lo anterior	F2 §6.14–§6.15: 40 pruebas y exportación con SHA-256	7 CSV y `manifest_f2.json`

Fuente: Elaboración propia a partir de los notebooks F1 y F2 y de los scripts de `src/`.

4.5.2. Registro de decisiones técnicas

Cada decisión tiene su entrada en `docs/decisiones.md`, con contexto, evidencia, alternativas descartadas y motivo:

Tabla 11. *Registro de decisiones técnicas (D-01 a D-09)*

Decisión	Resumen	Impacto medido
D-01	Versionar `data/processed/` y no `data/raw/`	Un clon limpio corre F1 y F2 sin descargar nada
D-02	Equivalencias CEN↔INE en archivos versionados	156 vínculos homologados por 4 equivalencias; 0 sin homologar
D-03	«Sobreestimar» en lugar de «inflar»	Precisión en la redacción del doble conteo
D-04	CSV sin conversión de saltos de línea	SHA-256 idénticos entre Windows y Linux
D-05	Duración solo con informes finalizados	954 de 1.834 informes prioritarios tienen duración válida
D-06	Tasa por 100.000 habitantes-año para comparar	10 de 15 comunas cambian de posición respecto del conteo
D-07	Título y pregunta alineados con el criterio poblacional	Coherencia entre F1, F2, README e informe
D-08	Conservar los atípicos y resumir con la mediana	Eliminarlos movería la mediana un −17,5 %
D-09	Rol y selección de las 28 variables; casting a `category`	−98,4 % de memoria en las categóricas, sin cambiar valores

Fuente: Elaboración propia a partir de `docs/decisiones.md` y de F2 §6.16.8.

4.5.3. Enfoques descartados

Tabla 12. *Enfoques descartados y motivo*

Enfoque	Por qué se descartó
Conjunto inicial NYC 311 (reclamos de alumbrado público)	Sin vínculo territorial chileno
Contar como informes distintos las menciones a varias comunas	Sobreestima la exposición
Homologación aproximada automática (*fuzzy matching*)	Podría unir comunas distintas con nombres parecidos
Imputar las fechas de término faltantes	Inventaría cierres que no ocurrieron (D-05)
Eliminar los atípicos	Borraría eventos documentados reales (D-08)
One-hot encoding	No hay modelos que lo requieran (D-09)

Fuente: Elaboración propia a partir de `docs/decisiones.md`, F1 §10.2 y F2 §4.5, §6.10.5 y §6.10.6.

4.6. Repositorio GitHub

Repositorio: https://github.com/jeanpaulsalasmeneses-lab/Proyecto_MCDI500

```
Proyecto_MCDI500/
├── F1/F1_Definición.ipynb        Fase 1: problema, entorno, mapa
├── F2/
│   ├── F2_Exploracion_y_Preprocesamiento.ipynb
│   └── figuras/                  figuras exportadas por F2
├── src/
│   ├── descargar_cen.py          obtención de los 33 ZIP del CEN
│   ├── consolidar_fallas_2024_2026.py    ZIP -> CSV
│   └── trazabilidad.py           entorno, versiones, commit
├── data/
│   ├── raw/         ZIP originales (se descargan, no se suben)
│   ├── external/    Censo 2024 del INE (URL y SHA-256)
│   ├── reference/   equivalencias CEN <-> INE
│   └── processed/   consolidados, salidas de F2, homologación
├── docs/            fuentes, decisiones, diccionario, entregas
├── requirements.txt    107 dependencias con versión exacta
└── README.md           descripción e instrucciones
```

El `README.md` describe el proyecto, la estructura, las dependencias y cómo ejecutar cada notebook en Windows y en Linux o macOS. También explica cómo reconstruir los datos desde la fuente original. Cada carpeta de datos tiene su propio `README.md` con su origen, en línea con los principios FAIR para software de investigación: código y datos localizables, accesibles y reutilizables (Barker et al., 2022). La estructura sigue la separación entre datos originales, externos y procesados que recomienda el material del curso (Salinas, 2026b).

Tabla 13. *Relación entre el repositorio y los apartados de este informe*

Ruta del repositorio	Contenido	Apartado del informe
`F1/F1_Definición.ipynb`	Definición, entorno, pruebas iniciales y mapa	III, IV.1–4.3, VI, VIII
`F2/F2_Exploracion_y_Preprocesamiento.ipynb`	Exploración, preprocesamiento, validación y exportación	V, VII
`F2/figuras/`	10 figuras de §6.12 y §6.13	VII (Figuras 5 a 14)
`src/`	Obtención, consolidación y trazabilidad	IV.3, IV.5.1, V.1
`data/reference/`	Equivalencias CEN↔INE	V.2.5
`data/processed/f2/`	7 CSV y `manifest_f2.json`	IV.3, VII.5
`docs/decisiones.md`	Decisiones D-01 a D-09	IV.5.2
`docs/verificacion_entorno.md`	Verificación en segundo equipo	IV.3
`docs/mapa_conceptual_F1_impacto_comunal.pdf`	Mapa conceptual	VIII (Figura 15)

Fuente: Elaboración propia a partir de la estructura del repositorio del proyecto.

V. DISEÑO DE SOLUCIONES ALGORÍTMICAS EFICIENTES

5.1. Codificación funcional

Tabla 14. *Funciones implementadas por componente*

Componente	Funciones	Ejemplos
F1	13	`localizar_proyecto`, `verificar_dataset`, `separar_comunas`, `consumo_reportado`
F2	30	`normalizar_comuna`, `crear_clave_region`, `auditar_asociacion`, `patron_fecha_termino`, `comparar_alternativas`, `perfil_variable`
`src/`	9	`descargar`, `zip_valido`, `verificar_dependencias`, `estado_git`, `informe_entorno`

Fuente: Elaboración propia a partir del código de F1, F2 y `src/`.

- **Un propósito por función:** cada una recibe parámetros y devuelve un resultado. Por ejemplo, `limites_iqr(serie, factor=1.5)` devuelve los límites y `resumen_duracion(serie)` los estadísticos.
- **Estructuras de control en lugar de bloques repetidos:** F2 tiene 45 bucles y 69 condicionales. Recorre los 33 períodos, los dos universos de análisis y las 28 variables, en vez de repetir código por columna (Salinas, 2026c).
- **Copias explícitas:** F2 usa `.copy()` en 31 puntos, para que una transformación no altere el conjunto original (Salinas, 2026a).
- **Flujo verificable:** cada etapa imprime sus conteos antes y después, y los `merge` declaran su cardinalidad (`validate="many_to_one"`).

La tabla siguiente describe, para funciones representativas, sus parámetros de entrada, el procesamiento que realizan y la salida que entregan, tal como están implementadas en los notebooks:

Tabla 15. *Entradas, procesamiento y salidas de funciones representativas*

Función (ubicación)	Entradas	Procesamiento y control	Salida
`verificar_dataset` (F1 §8.2)	`ruta_archivo`, `columnas_requeridas`, `minimo_filas`, `minimo_columnas`	Lee el CSV como texto sin depurarlo; `try/except` para CSV vacío o ilegible; valida columnas y dimensiones	DataFrame y resumen; `FileNotFoundError` o `ValueError` si falla
`separar_comunas` (F1 §8.2)	Valor del campo `Comuna`	Divide por «|», limpia espacios y elimina repetidos conservando el orden; no homologa	Lista de nombres (vacía si es nulo)
`consumo_reportado` (F1 §8.2)	Categoría de `Consumo`	Clasificación conservadora con condicionales; categorías no previstas quedan marcadas	`afectacion_reportada`, `sin_afectacion_reportada`, `sin_informacion` o `categoria_no_validada`
`normalizar_comuna` (F2 §5)	Texto de comuna	Limpia vacíos, elimina tildes con `unicodedata` y pasa a mayúsculas sin modificar el dato original	Clave comparable o `pd.NA`
`limites_iqr` (F2 §6.10.6)	`serie`, `factor=1.5`	Calcula Q1, Q3 y Q3 + 1,5·IQR	Tupla (Q1, Q3, límite superior)
`comparar_alternativas` (F2 §6.10.6)	Serie de duraciones	Evalúa tres tratamientos sobre copias y mide su efecto	Tabla comparativa de estadísticos
`ejecutar_prueba` (F2 §6.14)	`grupo`, `nombre`, `funcion`, `observacion`	Ejecuta la prueba dentro de `try/except` y registra el estado	Registro en `resultados_pruebas` (40 filas)
`calcular_sha256` (F2 §6.15)	Ruta de archivo	Lee el archivo por bloques de 1 MB y actualiza el hash	Huella SHA-256 hexadecimal

Fuente: Elaboración propia a partir del código fuente de F1 y F2.

Fragmentos de código comentados. La clave de comparación de comunas (F2 §5) elimina tildes y diferencias de mayúsculas sin modificar el dato original:

```
def normalizar_comuna(valor):
    texto = limpiar_texto(valor)        # espacios y vacíos -> NA
    if pd.isna(texto):
        return pd.NA
    # Separa cada letra de su tilde y descarta la tilde.
    texto = unicodedata.normalize("NFKD", texto)
    texto = "".join(
        c for c in texto if not unicodedata.combining(c)
    )
    return texto.upper()      # "Viña del Mar" -> "VINA DEL MAR"
```

La comparación de alternativas para los atípicos (F2 §6.10.6) trabaja sobre copias y mide el efecto de cada tratamiento antes de decidir:

```
def comparar_alternativas(serie):
    _, _, limite = limites_iqr(serie)      # Q3 + 1,5 * IQR
    p99 = serie.quantile(0.99)
    alternativas = {                       # siempre sobre copias
        "a) conservar todo": serie.copy(),
        "b) eliminar atípicos": serie[serie.le(limite)].copy(),
        "c) acotar al p99": serie.clip(upper=p99),
    }
    return pd.DataFrame(
        {n: resumen_duracion(s) for n, s in alternativas.items()}
    ).T
```

La separación de listas multicomuna de F1 §8.2 muestra el control de valores nulos y la eliminación de repetidos conservando el orden:

```
def separar_comunas(valor):
    """Divide una lista multicomuna; NO homologa nombres ni infiere cortes."""
    if pd.isna(valor):
        return []
    partes = (p.strip() for p in str(valor).split("|"))
    return list(dict.fromkeys(p for p in partes if p))
```

Limitación declarada. Parte de F2 todavía está escrita como celdas procedurales extensas. En F3, las funciones reutilizables de normalización y homologación se trasladarán a `src/` para importarlas en lugar de redefinirlas.

5.2. Preprocesamiento y transformación del dataset

5.2.1. Diagnóstico previo

El consolidado tiene 18.019 registros y 40 variables: 28 originales y 12 de procedencia y derivadas. No hay identificadores duplicados: cada `id_falla` aparece una sola vez en las 33 publicaciones. El diagnóstico se ejecutó en F2 §4 con la función `diagnosticar_calidad()`, que cuenta por variable los valores nulos y los campos vacíos sobre el conjunto cargado en memoria, sin eliminar registros ni modificar valores (F2 §4.2). La Figura 1 muestra el tipo de dato y los valores nulos de las 40 variables del consolidado.

Figura 1. *Tipo de dato, valores nulos y porcentaje de nulos de las 40 variables del conjunto consolidado*

	tipo_dato	nulos	no_nulos	porcentaje_nulos
Número	float64	0	18019	0.0
Tipo	str	0	18019	0.0
Estado	str	0	18019	0.0
Empresa	str	0	18019	0.0
Id Coordinado	float64	287	17732	1.59
Origen	str	0	18019	0.0
SubEstación	str	9148	8871	50.77
Elemento(s)	str	11460	6559	63.6
Zona Afectada	str	1092	16927	6.06
Comuna	str	1145	16874	6.35
Tipo Causa	str	0	18019	0.0
Causa	str	0	18019	0.0
Causa Definitiva	str	2153	15866	11.95
Causa Fenomeno Físico	str	1306	16713	7.25
Causa Elementos	str	1312	16707	7.28
Causa Fenomeno Eléctrico	str	1462	16557	8.11
Causa Modo	str	287	17732	1.59
Observaciones	str	54	17965	0.3
Acciones Inmediatas	str	57	17962	0.32
Hechos Sucedidos	str	51	17968	0.28
Acciones Correctivas a Corto Plazo	str	447	17572	2.48
Acciones Correctivas a Largo Plazo	str	782	17237	4.34
Consumo	str	287	17732	1.59
Distribuidoras Afectadas	str	11210	6809	62.21
Fecha Perturbación	str	0	18019	0.0
Fechas Estimada Retorno	str	0	18019	0.0
Fecha Efectiva Fin	str	7214	10805	40.04
Retorno Automático Falla	str	287	17732	1.59
anio_publicacion	int64	0	18019	0.0
mes_publicacion	int64	0	18019	0.0
archivo_zip	str	0	18019	0.0
archivo_csv	str	0	18019	0.0
fila_fuente	int64	0	18019	0.0
id_falla	int64	0	18019	0.0
anio_evento	int64	0	18019	0.0
mes_evento	int64	0	18019	0.0
intervalo_negativo	bool	0	18019	0.0
duracion_horas	float64	7214	10805	40.04
fecha_invalida_o_ausente	bool	0	18019	0.0
fuera_de_periodo	bool	0	18019	0.0

Fuente: Elaboración propia con Python (pandas) a partir del archivo `data/processed/cen_fallas_2024_2026_eventos.csv` (informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.)). Evidencia `F2_Tabla_datos_nulos_cen_fallas.png` proporcionada por el equipo; sus cifras coinciden con la salida de F2 §4 (ejecución 4).

Interpretación técnica. La figura confirma que `Fecha Perturbación`, `Estado`, `Tipo` y `Causa` están completas, mientras que las variables de detalle de instalación (`Elemento(s)`, `SubEstación`) y `Distribuidoras Afectadas` superan el 50 % de nulos. `Fecha Efectiva Fin` y la variable derivada `duracion_horas` comparten los mismos 7.214 nulos (40,04 %), lo que anticipa que la duración solo podrá calcularse para una parte de los informes. La figura cuenta solo valores nulos; F2 §4 suma además los campos vacíos, por lo que en tres variables causales el total de faltantes de la Tabla 17 es mayor (por ejemplo, `Causa Fenomeno Eléctrico`: 1.462 nulos y 361 vacíos).

Relación con el objetivo. El diagnóstico sustenta OE2: identifica qué variables pueden usarse para vincular informes con comunas (`Comuna`, 93,65 % completa) y cuáles no sirven como criterio único de afectación territorial (`Distribuidoras Afectadas`, 62,21 % faltante).

Tabla 16. *Dimensiones, unicidad y duplicados del conjunto consolidado*

Control	Resultado
Registros	18.019
Variables	40 (28 originales del CEN y 12 de procedencia y derivadas)
Identificadores ausentes o vacíos	0
Registros con identificadores repetidos	0
Filas completamente duplicadas	0
Meses de publicación presentes	33
Fechas de perturbación disponibles	18.019 (100 %)

Fuente: Elaboración propia a partir de F1 §8.2 (ejecución 3) y F2 §4 (ejecución 4) y §6.10 (ejecución 16).

Las variables con más faltantes son:

Tabla 17. *Variables con mayor proporción de valores faltantes*

Variable	Faltantes	%
Elemento(s)	11.460	63,60
Distribuidoras Afectadas	11.210	62,21
SubEstación	9.148	50,77
Fecha Efectiva Fin	7.214	40,04
Causa Definitiva	2.153	11,95
Comuna	1.145	6,35
Zona Afectada	1.092	6,06
Consumo	287	1,59

Fuente: Elaboración propia a partir del diagnóstico de calidad de F2 §4.3.1 (ejecución 4).

5.2.2. Roles de las variables y transformación según el rol (D-09)

Las 28 variables originales tienen un rol asignado: identificador, nominal, territorial, fecha, texto libre o procedencia. Cada una tiene también una decisión justificada, publicada en `docs/diccionario_variables.csv`:

- 10 se analizan;
- 6 se conservan para análisis propuestos en F3;
- 11 se descartan del análisis, aunque quedan en los archivos para mantener la trazabilidad;
- 1 es de procedencia.

La selección coincide en 25 de 28 columnas con la propuesta de depuración que hizo Jairo Barraza (documento interno del equipo, issue #7). Las tres diferencias se resolvieron con evidencia:

- `Estado` explica todos los faltantes de la fecha de término;
- `Tipo Causa` distingue la causa presunta de la definitiva;
- `Causa Definitiva` es la base de la recurrencia causal.

Transformaciones según el rol:

- **Categóricas:** casting a `category`. Reduce la memoria un 98,4 % (de 6,93 a 0,11 MB) sin cambiar ningún valor, comprobado con `assert`. No se aplica one-hot, porque no hay modelos, ni orden ordinal, porque ninguna categoría tiene un orden natural.
- **Fechas:** conversión a `datetime` en UTC (pandas development team, s. f.-a).
- **Texto territorial:** normalización a claves comparables.

Normalización de categorías operacionales (F2 §5 y §6.9). Los estados administrativos y las categorías de consumo se llevaron a mayúsculas sin perder el valor original. Los valores faltantes de `Consumo` se conservan explícitamente como `SIN_DATO`, sin imputarlos:

Tabla 18. *Estados administrativos y categorías de consumo normalizados*

Variable	Categoría	Base completa CEN	Informes prioritarios
Estado	FINALIZADO	10.802 (59,95 %)	954 (52,02 %)
Estado	PENDIENTE	6.138 (34,06 %)	750 (40,89 %)
Estado	ANULADO	1.079 (5,99 %)	130 (7,09 %)

Variable	Categoría	Base completa CEN	Informes prioritarios
Consumo	CONSUMO_NO_AFECTADO	10.901 (60,50 %)	708 (38,60 %)
Consumo	CONSUMO_REGULADO	3.932 (21,82 %)	589 (32,12 %)
Consumo	CONSUMO_LIBRE_REGULADO	1.878 (10,42 %)	341 (18,59 %)
Consumo	CONSUMO_LIBRE	1.021 (5,67 %)	174 (9,49 %)
Consumo	SIN_DATO	287 (1,59 %)	22 (1,20 %)

Fuente: Elaboración propia a partir de F2 §6.9 (ejecución 15).

5.2.3. Valores faltantes: patrón, alternativas y decisión (D-05)

Antes de decidir se midió el patrón de la fecha de término faltante (F2 §6.10.5). No es aleatorio: lo explica por completo el estado administrativo.

Tabla 19. *Presencia de fecha efectiva de término según estado administrativo (base completa)*

Estado	Con fecha de término	Sin fecha de término
Finalizado	10.802	0
Pendiente	0	6.138
Anulado	3	1.076

Fuente: Elaboración propia a partir de F2 §6.10.5 (ejecución 17).

Se compararon cuatro alternativas:

Tabla 20. *Alternativas evaluadas para la fecha de término faltante*

Alternativa	Evaluación
Imputar la mediana	Crearía cierres que no ocurrieron
Usar la fecha estimada de retorno	Es una estimación, no un cierre
Usar la fecha de publicación	Mide un trámite, no el evento
Calcular la duración solo con informes finalizados	**Elegida**

Fuente: Elaboración propia a partir de F2 §6.10.5 y `docs/decisiones.md` (D-05).

Los pendientes cuentan para la frecuencia, pero no para la duración, y los anulados se excluyen de los indicadores (pandas development team, s. f.-b).

Impacto declarado. En 2025, el 51 % de los informes prioritarios sigue pendiente. La causa principal es el apagón del 25 de febrero de 2025: el 83,5 % de sus 218 informes prioritarios está pendiente, frente al 39 % del resto del año. Por eso la duración subrepresenta ese evento, y las conclusiones de F3 deben decirlo.

5.2.4. Valores atípicos (D-08)

Con la regla IQR, 69 de 954 intervalos de informes finalizados prioritarios son atípicos (7,2 %), y el máximo llega a 1.073 horas. Las tres alternativas se compararon midiendo su efecto:

Tabla 21. *Efecto de los tratamientos de atípicos sobre la duración documental (15 comunas, finalizados)*

Alternativa	Media	Cambio en la media	Mediana	Cambio en la mediana
Conservar todo	6,65 h	—	1,60 h	—
Eliminar atípicos	2,52 h	−62,1 %	1,32 h	−17,5 %
Acotar al p99	3,74 h	−43,8 %	1,60 h	0,0 %

Fuente: Elaboración propia a partir de F2 §6.10.6 (ejecución 18).

Decisión. Se conservan todos los intervalos, porque son eventos reales con fechas válidas, y la duración se resume con mediana y percentiles. La mediana no cambia al acotar los extremos, así que es pertinente para comparar comunas (OE4). Como toda medida robusta, sacrifica sensibilidad a los eventos largos. Por eso,

en F3 cada comuna informará también cuántos de sus intervalos son atípicos.

5.2.5. Normalización y homologación territorial (D-02)

Separar el campo `Comuna` por «|» produjo 23.284 vínculos de 16.874 informes, sin vínculos duplicados. La homologación con el maestro del INE (346 comunas) tuvo tres pasos:

Tabla 22. *Pasos de la homologación territorial CEN–INE*

Paso	Vínculos homologados	% acumulado
Coincidencia exacta de la clave normalizada	23.128	99,33
Equivalencias con validación regional	128	99,88
Equivalencias con validación multirregional	28	100,00

Fuente: Elaboración propia a partir de F2 §6.6.3–§6.6.5 (ejecuciones 9 a 11).

Las cuatro equivalencias (Llay Llay, San Vicente de Tagua Tagua, Treguaco y Paiguano) viven en `data/reference/equivalencias_comunas.csv`. Ninguna corresponde a las 15 comunas analizadas. La auditoría geográfica posterior (F2 §6.7, ejecución 13) clasificó las 23.284 asociaciones como coincidentes con la región declarada en `Zona Afectada` (100 %).

5.2.6. Normalización por población (D-06)

Para comparar comunas de distinto tamaño, la exposición se expresa como informes no anulados por 100.000 habitantes-año. Los años observados son 33 meses / 12 = 2,75. El conteo absoluto no crece con la población (Spearman = −0,27), y al pasar a la tasa 10 de las 15 comunas cambian de posición: por ejemplo, Puente Alto baja del 3.º al 8.º lugar. La tasa se informa siempre junto con el conteo, y se declara que el resultado depende del denominador (detalle en la Tabla 30).

5.2.7. Conjunto resultante y coherencia con los objetivos

El conjunto procesado se exporta en siete archivos CSV (Tabla 31, apartado 7.5). Cada transformación responde a un objetivo:

- la homologación, a OE2;
- la selección poblacional, a OE3;
- el tratamiento de faltantes y atípicos y el denominador, a OE4;
- la conservación de la procedencia y de las columnas originales, a la trazabilidad que exige todo el proyecto.

5.3. Validación técnica y verificación del código

F1: 6 pruebas de casos normales, límite y excepciones, todas aprobadas (F1 §8.3, ejecución 4):

Tabla 23. *Pruebas funcionales iniciales de F1*

N.º	Escenario	Tipo de caso	Resultado
P1	CSV válido	Normal	Aprobada
P2	Archivo ausente	Excepción	Aprobada
P3	Archivo vacío	Excepción	Aprobada
P4	Columna territorial ausente	Excepción	Aprobada
P5	Separación y eliminación de nombres repetidos	Límite	Aprobada
P6	Clasificación conservadora de consumo	Límite	Aprobada

Fuente: Elaboración propia a partir de la salida de F1 §8.3 (ejecución 4).

F2: 40 pruebas automatizadas en 10 grupos, todas aprobadas y exportadas a `07_cen_validaciones_tecnicas.csv` (F2 §6.14, ejecución 26). El detalle de las 40 pruebas está en el Anexo B.

Tabla 24. *Pruebas automatizadas de F2 por grupo de validación*

Grupo	Pruebas	Grupo	Pruebas
Normalización	5	Integridad documental	4
Auditoría geográfica	4	Integridad territorial	4
Clasificación operacional	5	Conjunto prioritario	5
Conversión temporal	5	Calidad temporal	3
Control de excepciones	1	Consistencia causal	4

Fuente: Elaboración propia a partir de la salida de F2 §6.14.5 (ejecución 26).

- **Comprobaciones en cada etapa:** F2 contiene 149 instrucciones `assert` que detienen la ejecución donde se origina un problema. Algunas comprueban que no se pierdan informes, que no se dupliquen vínculos, que las tablas cuadren y que el casting no cambie valores. Otras fijan la evidencia de las decisiones: si datos nuevos rompen el patrón de la D-05, el notebook avisa que hay que revisarla.
- **Evidencia conservada:** los notebooks se entregan con sus salidas: conteos antes y después, tablas y perfiles del conjunto final.
- **Alcance de la validación:** como declara F2 §6.14.5, la aprobación del 100 % de las pruebas respalda la consistencia funcional dentro del alcance de las pruebas ejecutadas; no constituye una auditoría independiente de la exactitud de los informes originales del CEN.

VI. NOTEBOOK F1: DEFINICIÓN Y ENTORNO

`F1/F1_Definición.ipynb` contiene:

- **Celdas narrativas:** problemática, pregunta, objetivos, alcance, metodología y referencias.
- **Verificación del entorno:** versión de Python, entorno virtual, 106 dependencias, commit y semilla.
- **Verificación estructural del consolidado:** reconocimiento inicial de los datos.
- **Seis pruebas iniciales.**
- **El mapa conceptual.**

Alcance respetado: F1 no limpia, no imputa ni transforma. Lee el CSV sin modificarlo y solo calcula resúmenes. El notebook corre completo con *Restart Kernel and Run All Cells*, con numeración de ejecución continua.

Tabla 25. *Estructura del notebook F1 y correspondencia con el proyecto*

Sección de F1	Contenido	Tipo de celda / ejecución
§1–§4	Contextualización, problema, pregunta analítica y justificación	Narrativa
§5	Objetivo general, objetivos específicos y articulación F1–F4	Narrativa
§6	Alcance, delimitación, variables, indicadores, restricciones y supuestos	Narrativa
§7	Metodología de procesamiento y estrategia de validación	Narrativa
§8.1–§8.1.1	Verificación del entorno y trazabilidad (`src/trazabilidad.py`)	Código, ejecuciones 1 y 2
§8.2	Verificación estructural y factibilidad del análisis comunal	Código, ejecución 3
§8.3	Seis pruebas normales, límite y de excepción	Código, ejecución 4
§9	Mapa conceptual, glosario y vinculación con evidencias	Código, ejecución 5
§10–§11	Control de versiones, reproducibilidad y referencias APA 7	Narrativa

Fuente: Elaboración propia a partir del notebook `F1/F1_Definición.ipynb` (18 celdas: 13 narrativas y 5 de código).

El diagnóstico de factibilidad de F1 §8.2 (ejecución 3) obtuvo, sin transformar el archivo, los siguientes resultados:

Tabla 26. *Resultados del diagnóstico de factibilidad comunal de F1*

Indicador	Resultado
Registros / variables	18.019 / 40
Columnas requeridas verificadas	9
Meses de publicación presentes	33
Identificadores faltantes	0
Informes con comuna declarada	16.874
Informes multicomuna	2.623
Comunas mencionadas (sin homologar)	320
Consumo: sin afectación / con afectación reportada / sin información	10.901 / 6.831 / 287
Estado de la verificación	ESTRUCTURA VERIFICADA; homologación INE pendiente para F2

Fuente: Elaboración propia a partir de la salida de F1 §8.2 (ejecución 3).

Trazabilidad entre objetivos, entorno, código y mapa. Los objetivos de F1 §5 se vinculan con el entorno verificado en §8.1, con las funciones de §8.2–§8.3 (que comprueban la viabilidad de OE1 y OE2 sin anticipar procedimientos de F2) y con el mapa de §9, que representa el ciclo completo del dato. Los procedimientos de homologación, selección de comunas y validación integral se documentan en F2 y no se atribuyen a F1.

VII. NOTEBOOK F2: EXPLORACIÓN Y PREPROCESAMIENTO

7.1. Estructura del notebook

`F2/F2_Exploracion_y_Preprocesamiento.ipynb` sigue el flujo que pide la guía, con una celda narrativa al inicio de cada etapa. Contiene 74 celdas (46 narrativas y 28 de código), ejecutadas de forma continua (ejecuciones 1 a 28) y sin errores.

Tabla 27. *Etapas del notebook F2 y secciones correspondientes*

Etapa	Secciones	Ejecuciones
Entorno	§0	1
Obtención y carga	§1–§3	2–3
Exploración y calidad	§4	4–5
Limpieza y normalización	§5	6
Integración y homologación	§6.5–§6.7	7–13
Transformación	§6.8–§6.10	14–18
Caracterización	§6.11–§6.13	19–25
Validación	§6.14	26
Exportación	§6.15	27–28
Conclusiones	§6.16	—

Fuente: Elaboración propia a partir del notebook `F2/F2_Exploracion_y_Preprocesamiento.ipynb`.

El notebook corre completo, con numeración continua, y exporta el conjunto procesado a `data/processed/`, que es la entrada directa de F3.

7.2. Obtención, exploración y limpieza

La carga (ejecución 2) leyó `cen_fallas_2024_2026_eventos.csv` con 18.019 registros y 40 variables y verificó la presencia de las columnas requeridas, sin modificar los datos. La exploración inicial (ejecución 3) cuantificó faltantes, la distribución de `Consumo`, los 16.874 registros con comuna, los 2.623 con varias comunas y la ausencia de identificadores faltantes o repetidos. El diagnóstico de calidad (ejecución 4), los roles de variables (ejecución 5) y la normalización territorial (ejecución 6) se describen en el apartado 5.2.

7.3. Resultados intermedios: integración de las 15 comunas prioritarias

El maestro territorial (F2 §6.5, ejecución 8) reunió 346 comunas con código único y una población nacional censada de 18.480.432 habitantes. Las 15 comunas de mayor población se seleccionaron por ordenamiento poblacional y se integraron con los informes (F2 §6.8, ejecución 14):

Tabla 28. *Comunas prioritarias: población censada e informes asociados*

N.º	Comuna	Región	Población 2024	Informes asociados
1	Puente Alto	Metropolitana de Santiago	568.086	157
2	Maipú	Metropolitana de Santiago	503.635	36
3	Santiago	Metropolitana de Santiago	438.856	73
4	Antofagasta	Antofagasta	401.096	547
5	La Florida	Metropolitana de Santiago	374.836	88
6	Viña del Mar	Valparaíso	334.871	68
7	San Bernardo	Metropolitana de Santiago	306.371	75
8	Las Condes	Metropolitana de Santiago	296.134	38
9	Temuco	La Araucanía	292.518	107
10	Valparaíso	Valparaíso	284.938	105

N.º	Comuna	Región	Población 2024	Informes asociados
11	Puerto Montt	Los Lagos	277.040	59
12	Coquimbo	Coquimbo	263.719	128
13	Rancagua	Libertador General Bernardo O'Higgins	257.744	148
14	La Serena	Coquimbo	250.141	106
15	Arica	Arica y Parinacota	241.653	180
	Total			**1.915 asociaciones / 1.834 informes distintos**

Fuente: Elaboración propia a partir de F2 §6.5.2 y §6.8 (ejecuciones 8 y 14), con datos del Censo 2024 (INE, 2025) y informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.).

La diferencia de 81 entre asociaciones (1.915) e informes distintos (1.834) se debe a que 71 informes mencionan más de una comuna prioritaria; por eso la suma de los conteos comunales supera el número de informes únicos.

7.4. Resultados exploratorios

Los resultados de esta sección son descriptivos y documentales. En todos ellos se mantiene la distinción establecida en F1: los conteos corresponden a informes y asociaciones del CEN, no a interrupciones efectivas, clientes afectados ni energía no suministrada.

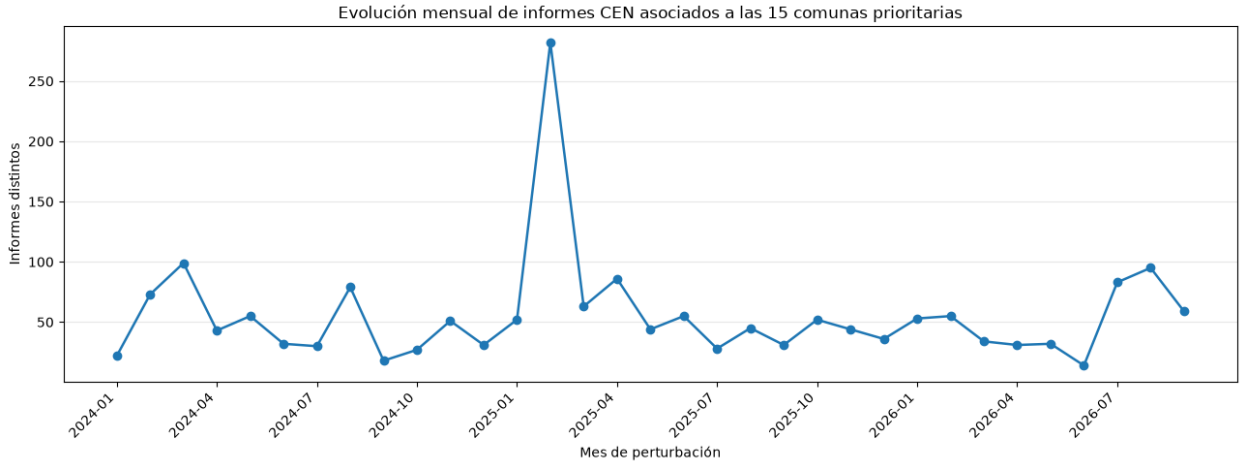
7.4.1. Calidad del conjunto de datos

La calidad del conjunto se diagnosticó sobre 18.019 registros y 40 variables (Figura 1 y Tablas 16 y 17). No hay duplicados completos ni identificadores repetidos; los tipos de dato son coherentes con el rol de cada variable (texto para categorías y descripciones, enteros para año, mes y fila de origen, y booleanos para las banderas de calidad temporal); la información temporal de inicio está completa, mientras que la fecha de término falta en el 40,04 % de los registros. Las decisiones adoptadas fueron conservar los 18.019 informes, priorizar las variables comunales y de consumo, diferenciar los estados administrativos y validar las variables temporales antes de calcular duraciones (F2 §4.4).

7.4.2. Evolución temporal, distribución territorial y consumo

F2 §6.11 construyó tres visualizaciones exploratorias iniciales sobre los 1.834 informes distintos y las 1.915 asociaciones. La Figura 2 muestra la evolución mensual de los informes asociados a las comunas prioritarias.

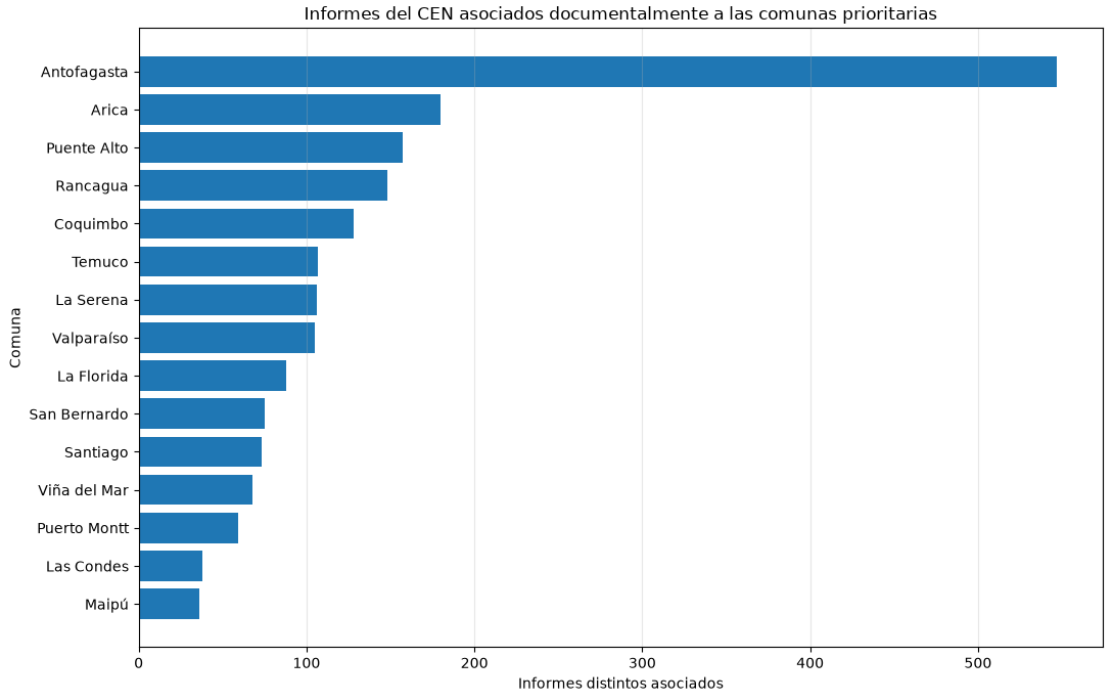
Figura 2. *Evolución mensual de informes CEN asociados a las 15 comunas prioritarias (enero de 2024 a septiembre de 2026)*



Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.11; figura extraída de la salida de la ejecución 19.

Interpretación técnica. El máximo corresponde a febrero de 2025, con 282 informes (15,38 % del conjunto prioritario). Se observan concentraciones secundarias en marzo de 2024, agosto de 2024, abril de 2025 y agosto de 2026. **Limitación:** 2026 solo tiene información hasta septiembre, por lo que su volumen acumulado no se compara directamente con años completos (F2 §6.11.4).

Figura 3. *Informes del CEN asociados documentalmente a cada comuna prioritaria*

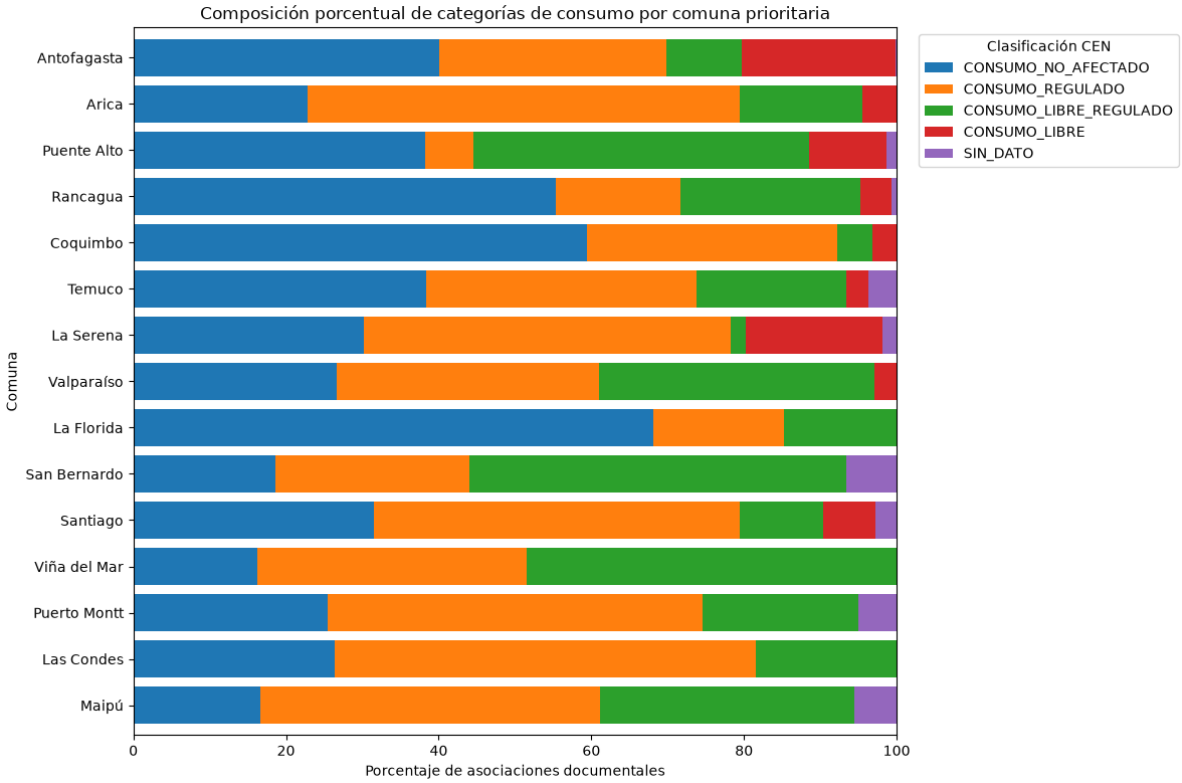


Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.11; figura extraída de la salida de la ejecución 19.

Interpretación técnica. Antofagasta concentra 547 informes asociados, seguida por Arica (180), Puente Alto (157), Rancagua (148) y Coquimbo (128); Maipú (36) y Las Condes (38) registran los menores valores. La cantidad de informes no es proporcional a la población: Puente Alto es la comuna más poblada y

Antofagasta la de más informes. **Relación con el objetivo:** es el insumo de la frecuencia documental (OE3–OE4). **Limitación:** la suma de las barras (1.915) supera los 1.834 informes únicos porque un informe puede asociarse a varias comunas.

Figura 4. *Composición porcentual de categorías de consumo por comuna prioritaria*



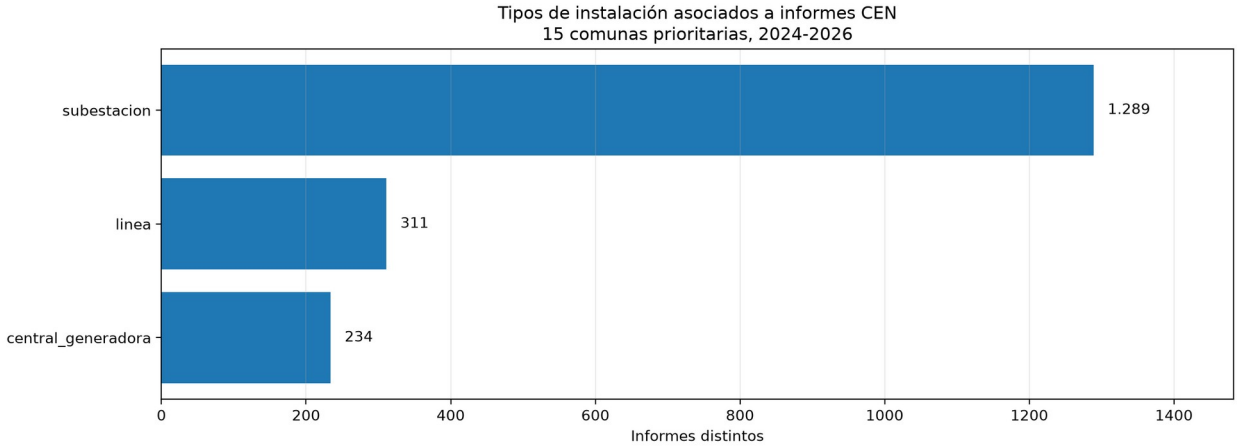
Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.11; figura extraída de la salida de la ejecución 19.

Interpretación técnica. En La Florida, Coquimbo y Rancagua predomina `CONSUMO_NO_AFECTADO`; en Arica, Las Condes, Maipú y La Serena tiene una participación relevante `CONSUMO_REGULADO`, y en Puente Alto, San Bernardo y Viña del Mar destaca `CONSUMO_LIBRE_REGULADO`. **Limitación:** los porcentajes son la composición interna de las asociaciones de cada comuna y no miden clientes afectados; deben leerse junto con el número de registros de cada comuna.

7.4.3. Caracterización de instalaciones

F2 §6.12 caracterizó los 1.834 informes prioritarios según el tipo de instalación declarado en la variable `Tipo`.

Figura 5. *Tipos de instalación asociados a informes CEN en las 15 comunas prioritarias (2024–2026)*



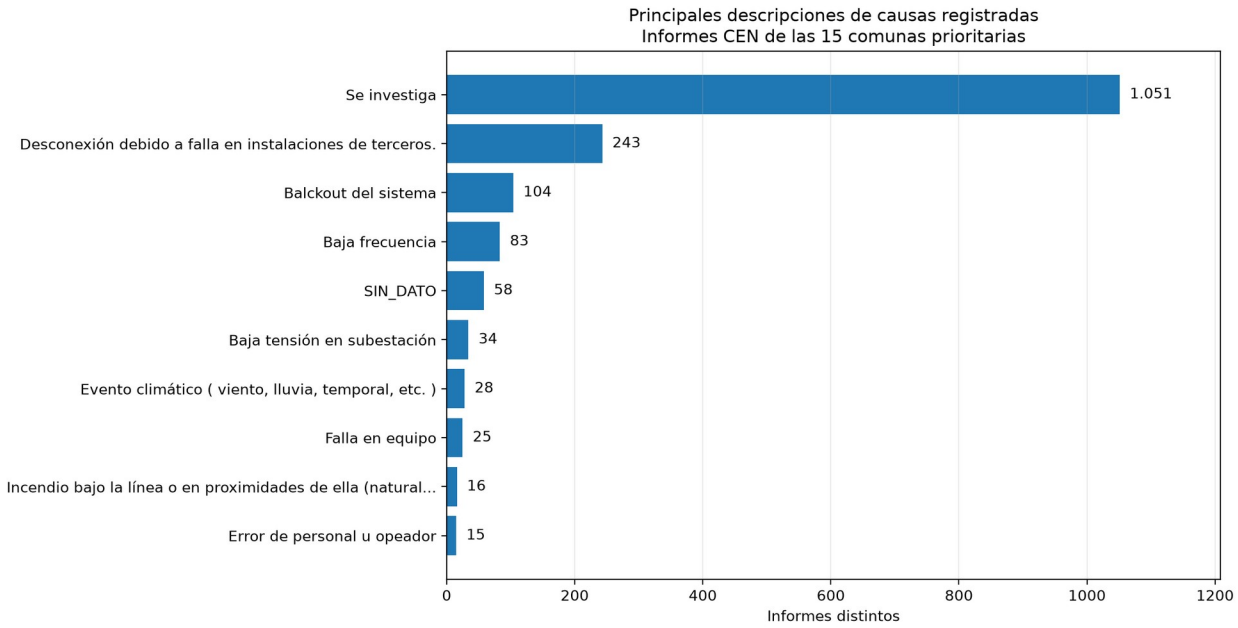
Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.12.6; archivo `F2/figuras/F2_612_Figura_01_Tipos_Instalacion.png`.

Interpretación técnica. Las subestaciones concentran 1.289 informes (70,28 %), seguidas por las líneas, con 311 (16,96 %), y las centrales generadoras, con 234 (12,76 %). El 70,45 % de los informes declara origen externo y el 29,55 %, origen interno. **Relación con el objetivo:** identifica el tipo de instalación predominante en la documentación de las comunas (OE3). **Limitación:** el predominio es documental: no demuestra que las subestaciones tengan una mayor tasa de fallas ni una menor confiabilidad física, porque no se dispone de una base de exposición comparable por tipo de instalación (F2 §6.12.5).

7.4.4. Clasificación causal

La información causal combina dos variables: `Tipo Causa`, que indica si la causa es presunta o definitiva, y `Causa Definitiva`, que contiene la descripción registrada. F2 §6.12 y §6.13.5 distinguen tres condiciones: **no determinada** (descripciones «Se investiga» o sin dato), **presunta** y **definitiva**.

Figura 6. *Principales descripciones de causas registradas en los informes CEN de las 15 comunas prioritarias*



Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional

(CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.12.6; archivo `F2/figuras/F2_612_Figura_02_Causas.png`. Las etiquetas se transcriben como aparecen en la fuente, incluidas sus erratas («Balckout», «opeador»).

Interpretación técnica. «Se investiga» concentra 1.051 informes (57,31 %) y `SIN_DATO`, 58; juntos suman los 1.109 informes sin causa determinada (60,47 %). Entre las descripciones específicas destacan la desconexión por falla en instalaciones de terceros (243), «Balckout del sistema» (104) y baja frecuencia (83).

Tabla 29. *Condición de la información causal en los informes prioritarios*

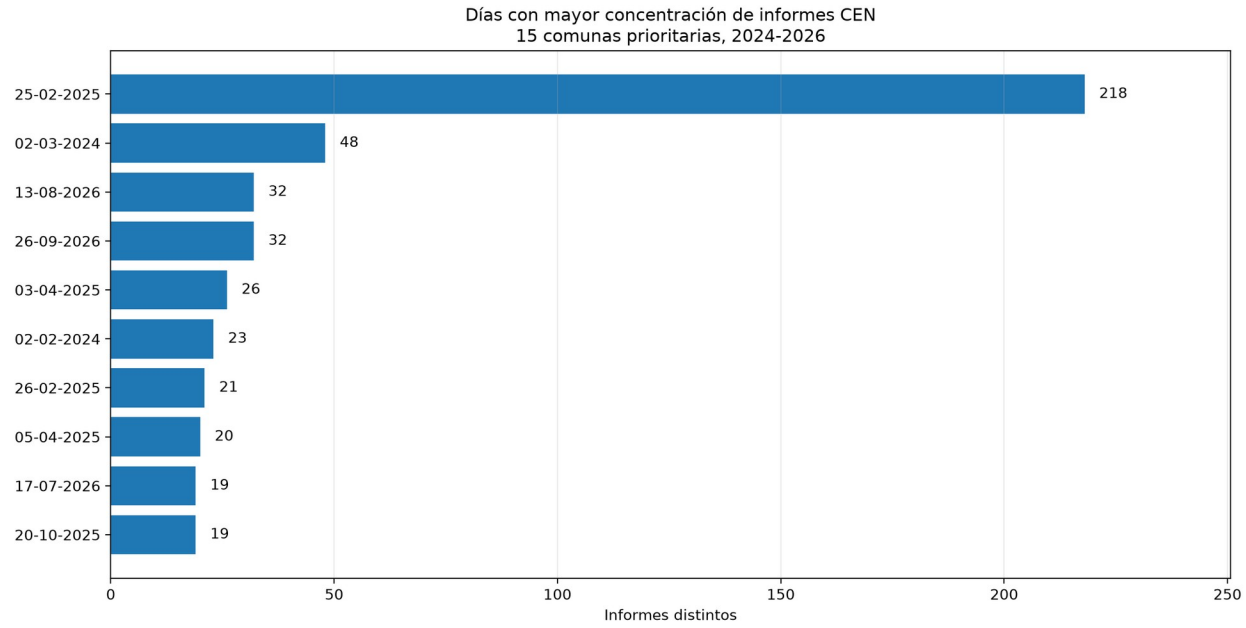
Condición	Criterio	Informes	%
Causa presunta (`Tipo Causa`)	Clasificación administrativa del CEN	1.282	69,90
Causa definitiva (`Tipo Causa`)	Clasificación administrativa del CEN	552	30,10
No determinada	Descripción «Se investiga» (1.051) o `SIN_DATO` (58)	1.109	60,47
Con descripción específica	Descripción causal concreta	725	39,53
de ellas, definitivas	Descripción específica y condición definitiva	385	—
de ellas, presuntas	Descripción específica y condición presunta	340	—

Fuente: Elaboración propia a partir de F2 §6.12.5 (ejecución 20) y §6.13.5 (ejecución 23).

Limitación. Ambos cortes usan denominadores distintos y no se contradicen: `Tipo Causa` clasifica los 1.834 informes, mientras que la condición «no determinada» se basa en el texto de la descripción. Una causa clasificada como definitiva corresponde a la información proporcionada por el CEN y no a una verificación causal independiente.

7.4.5. Concentración temporal

Figura 7. *Días con mayor concentración de informes CEN en las 15 comunas prioritarias (2024–2026)*



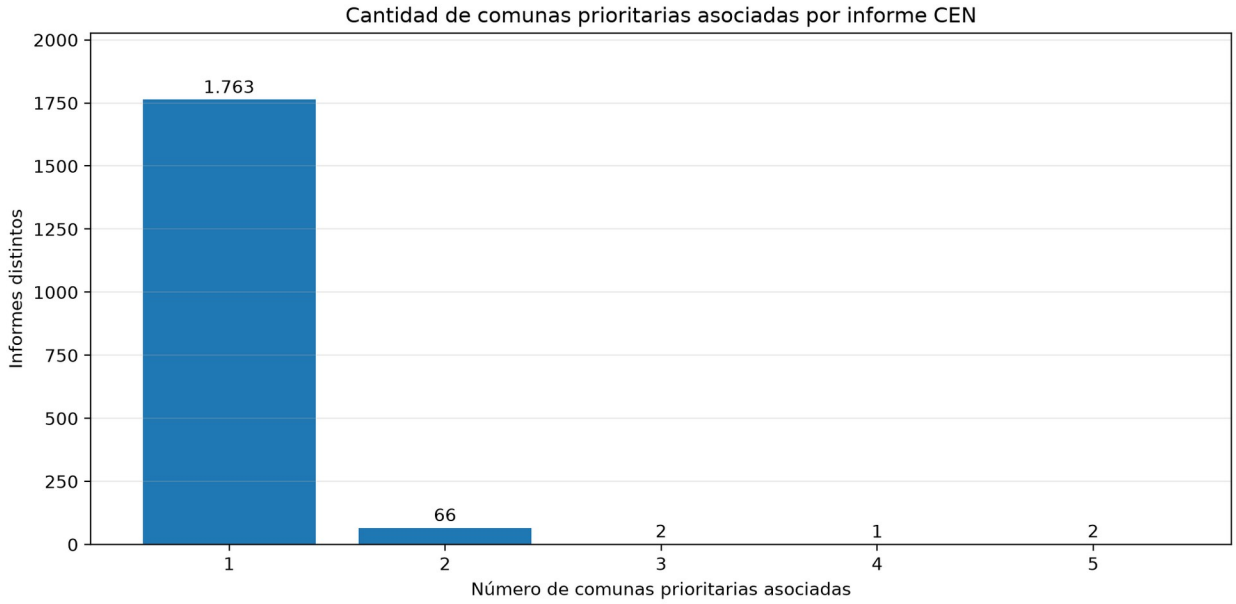
Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.12.6; archivo `F2/figuras/F2_612_Figura_03_Concentracion_Diaria.png`.

Interpretación técnica. El **25 de febrero de 2025** concentra 218 informes distintos (11,89 % del conjunto prioritario) y supera ampliamente los 48 del 2 de marzo de 2024, segunda fecha. En ese día, 183 informes se asocian a subestaciones, 27 a centrales generadoras y 8 a líneas; 92 tienen la descripción «Balckout del

sistema», 72 «Se investiga» y 182 siguen pendientes. **Relación con el objetivo:** identifica el principal acontecimiento para el análisis de recurrencia temporal (OE4). **Limitación:** los 218 informes no equivalen a 218 fallas físicas independientes ni se atribuyen automáticamente a un único acontecimiento sin comprobar sus relaciones documentales (F2 §6.12.5).

7.4.6. Alcance territorial

Figura 8. *Cantidad de comunas prioritarias asociadas por informe CEN*

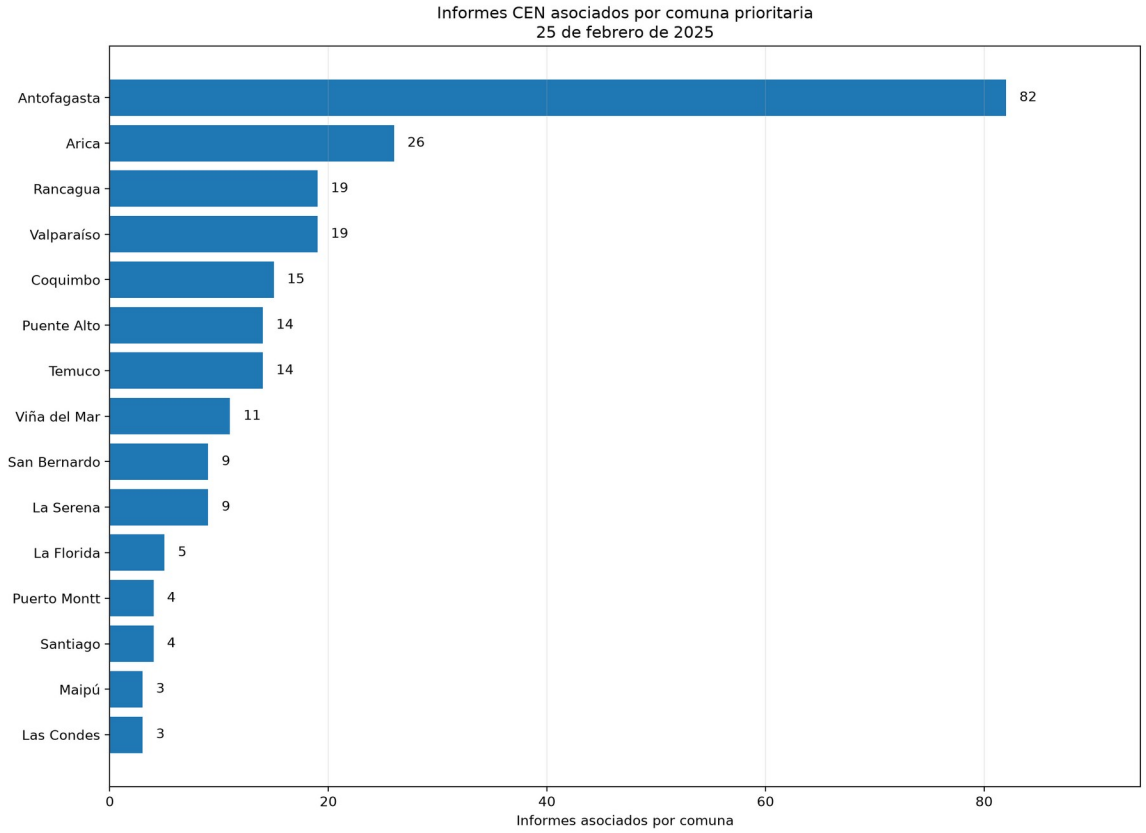


Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.12.6; archivo `F2/figuras/F2_612_Figura_04_Alcance_Territorial.png`.

Interpretación técnica. 1.763 informes se asocian a una sola comuna prioritaria y 71 a dos o más: 66 a dos comunas, 2 a tres, 1 a cuatro y 2 a cinco. Un **informe único** es un registro del CEN identificado por `id_falla`; una **asociación documental** es cada vínculo entre ese informe y una comuna mencionada. Por eso los 1.834 informes producen 1.915 asociaciones, sin que la diferencia represente fallas adicionales. **Limitación:** la cantidad de comunas asociadas mide alcance documental, no el territorio efectivamente interrumpido.

7.4.7. Distribución por comuna el 25 de febrero de 2025

Figura 9. *Informes CEN asociados por comuna prioritaria el 25 de febrero de 2025*

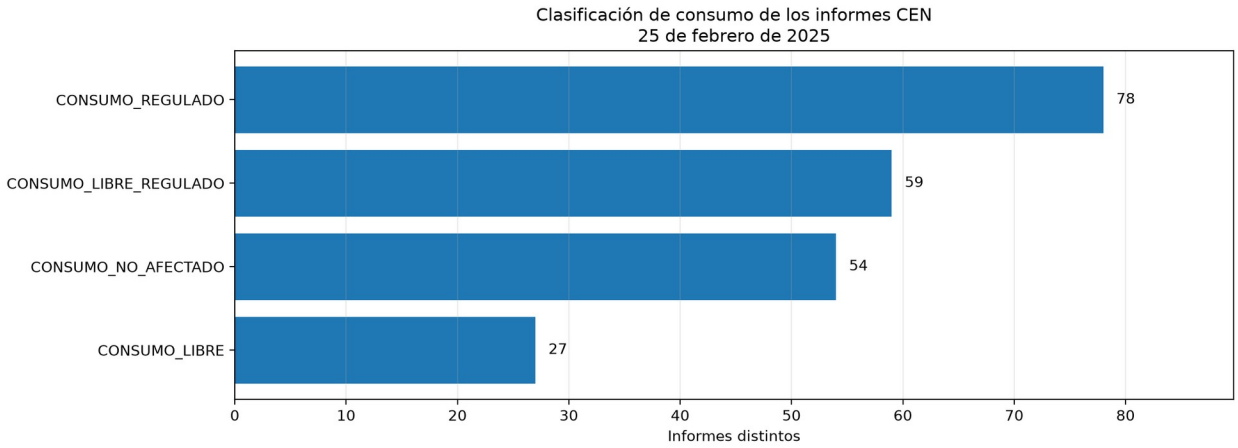


Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.12.6; archivo `F2/figuras/F2_612_Figura_05_Comunas_Febrero_2025.png`.

Interpretación técnica. Las 15 comunas prioritarias tienen informes asociados ese día. Antofagasta presenta 82, seguida por Arica (26), Rancagua y Valparaíso (19 cada una) y Coquimbo (15); Maipú y Las Condes registran 3 cada una. La suma de las barras (237) es mayor que los 218 informes de la fecha porque algunos informes se asocian a varias comunas. **Limitación:** la distribución describe asociaciones documentales y no permite determinar la magnitud de las interrupciones efectivas en cada comuna.

7.4.8. Clasificación del consumo el 25 de febrero de 2025

Figura 10. *Clasificación de consumo de los informes CEN del 25 de febrero de 2025*



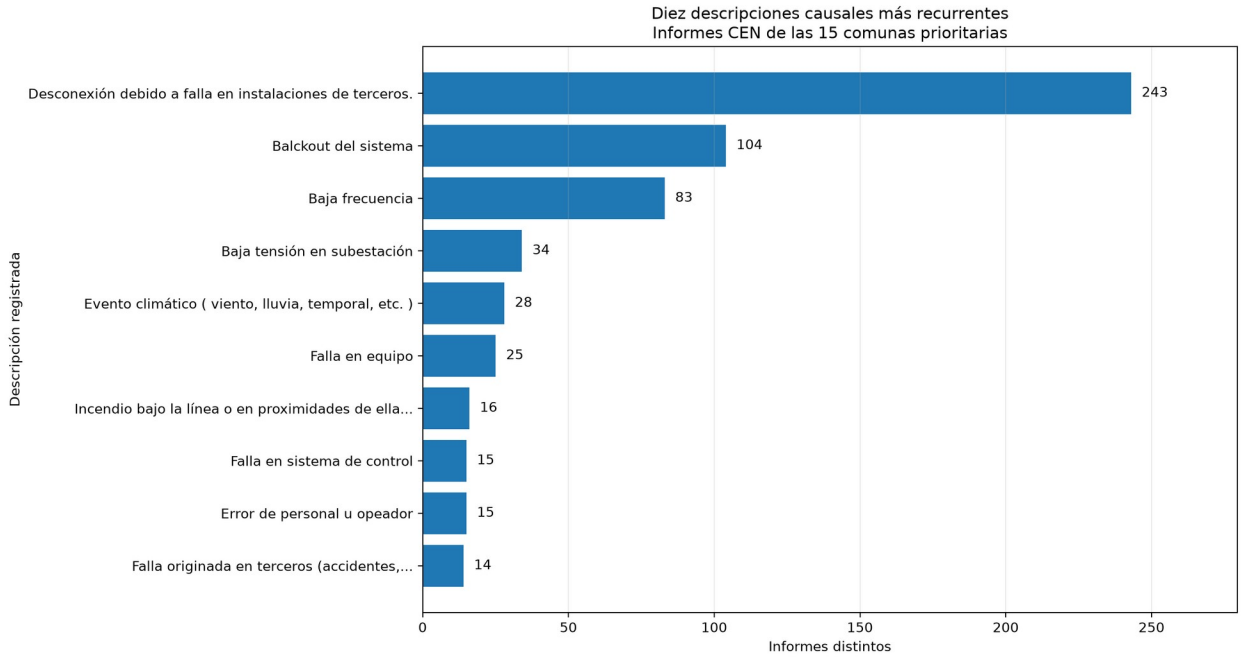
Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.12.6; archivo `F2/figuras/F2_612_Figura_06_Consumo_Febrero_2025.png`.

Interpretación técnica. De los 218 informes de la fecha, 78 corresponden a `CONSUMO_REGULADO` (35,78 %), 59 a `CONSUMO_LIBRE_REGULADO` (27,06 %), 54 a `CONSUMO_NO_AFECTADO` (24,77 %) y 27 a `CONSUMO_LIBRE` (12,39 %). Las categorías regulado, libre y mixto suman 164 informes con afectación de consumo reportada. **Relación con el objetivo:** responde a la parte de la pregunta analítica sobre la exposición asociada a afectación de consumo reportada. **Limitación:** las categorías no indican la cantidad de clientes afectados.

7.4.9. Recurrencia de causas

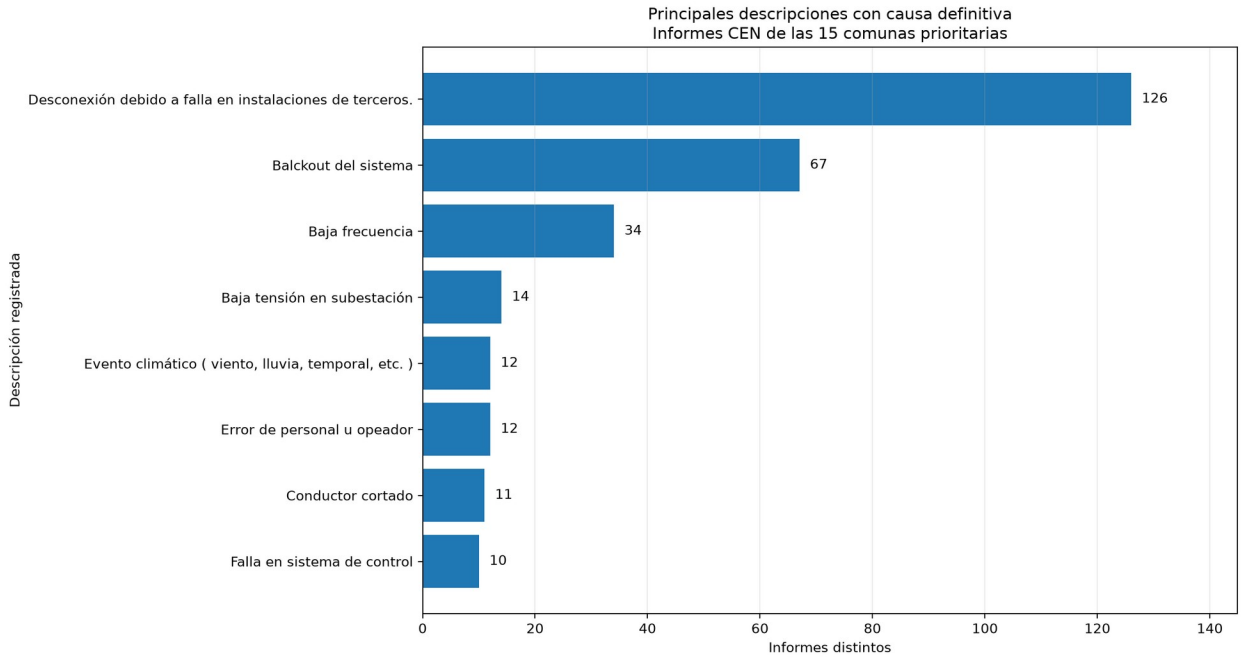
F2 §6.13.5–§6.13.6 analizó la recurrencia de las descripciones causales específicas, excluyendo las no determinadas.

Figura 11. *Diez descripciones causales más recurrentes en los informes CEN de las 15 comunas prioritarias*



Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.13.6; archivo `F2/figuras/F2_613_Figura_01_Recurrencia_General.png`.

Figura 12. *Principales descripciones con causa definitiva en los informes CEN de las 15 comunas prioritarias*



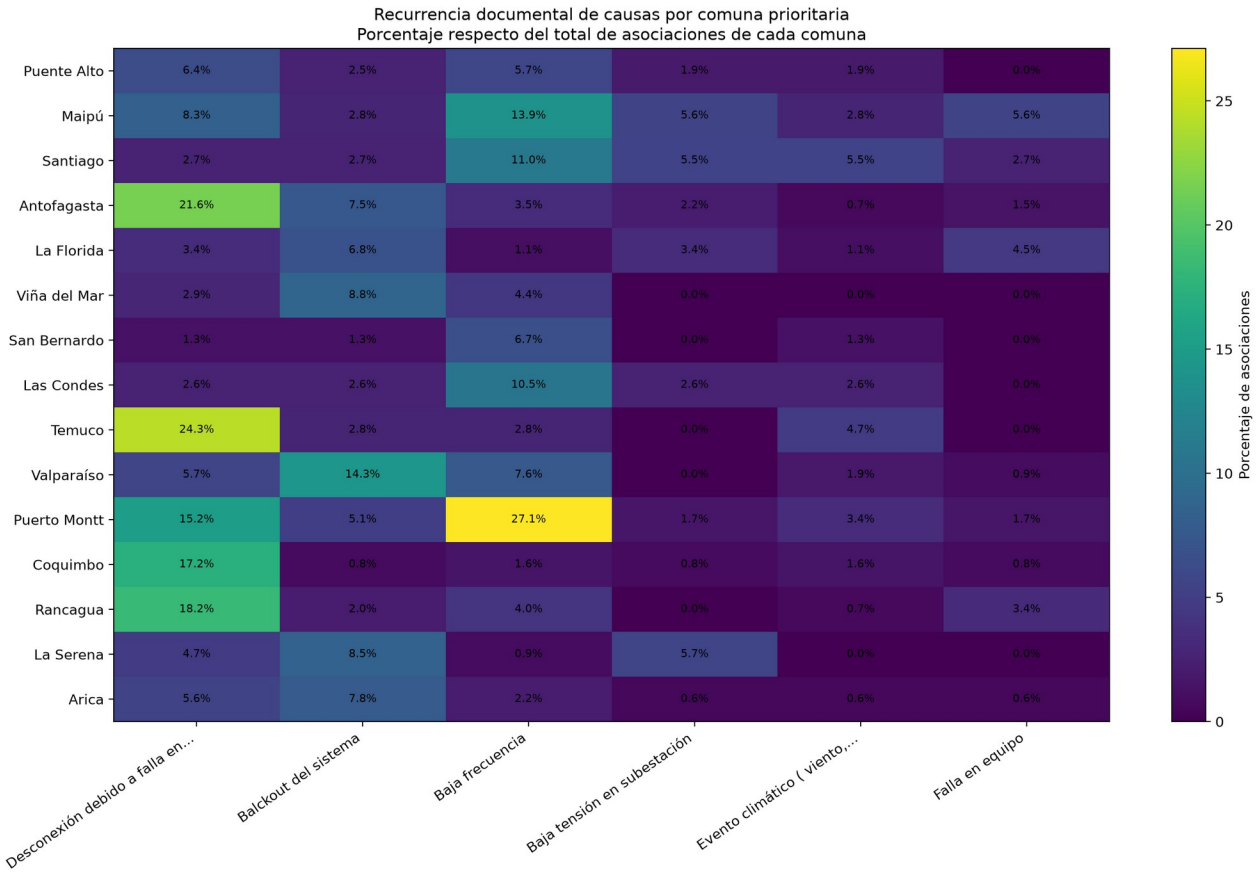
Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.13.6; archivo `F2/figuras/F2_613_Figura_02_Causas_Definitivas.png`.

Interpretación técnica. La desconexión por falla en instalaciones de terceros es la descripción específica más recurrente (243 informes; 126 con causa definitiva), seguida por «Balckout del sistema» (104; 67 definitivas) y baja frecuencia (83; 34 definitivas). La comparación entre ambas figuras muestra que no todas

las descripciones recurrentes tienen el mismo grado de determinación causal. **Limitación:** la **recurrencia documental** es la repetición de una descripción entre informes; no equivale a **recurrencia física** de fallas sobre un mismo equipo, ya que un acontecimiento sistémico puede generar varios informes con la misma descripción (F2 §6.13.5).

7.4.10. Matriz de recurrencia comunal

Figura 13. *Recurrencia documental de las seis principales descripciones causales por comuna prioritaria (porcentaje de asociaciones de cada comuna)*

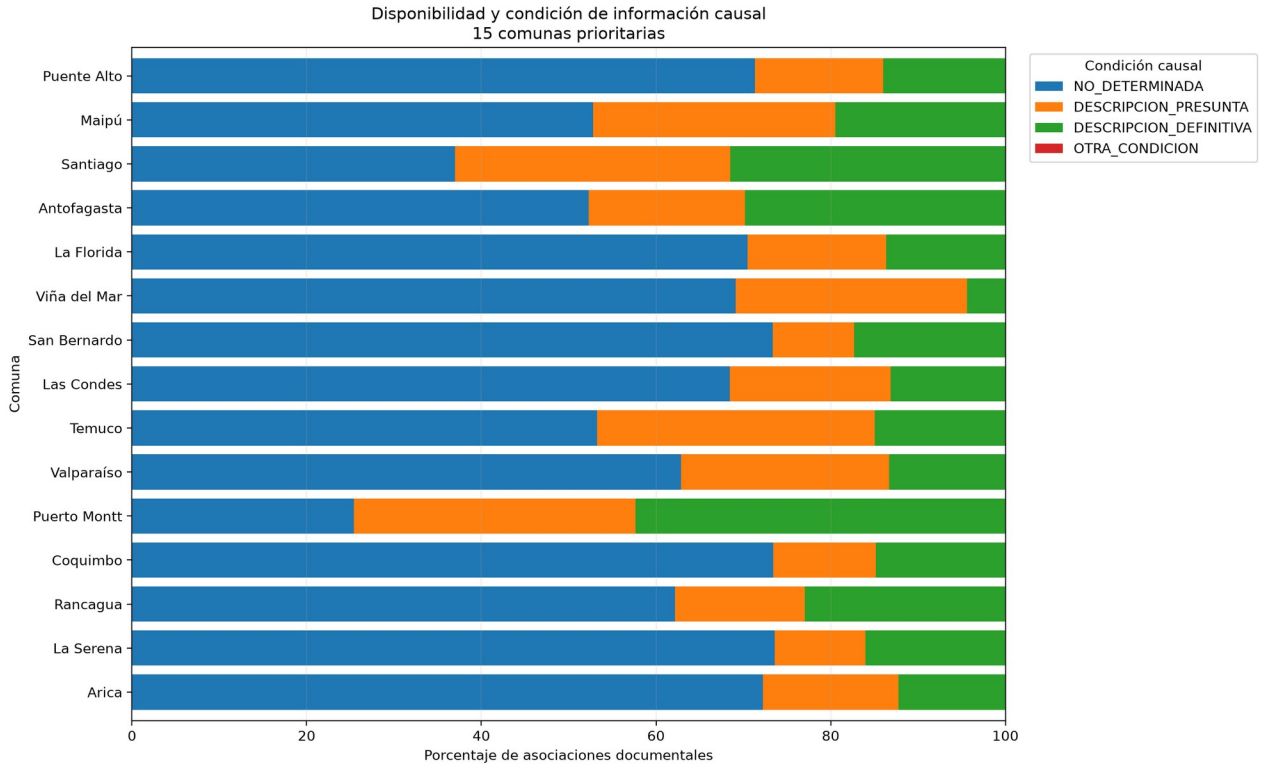


Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.13.6; archivo `F2/figuras/F2_613_Figura_03_Matriz_Recurrencia_Comunal.png`.

Interpretación técnica. El denominador de cada fila es el total de asociaciones documentales de la comuna, incluidas las que tienen causa no determinada. Destacan la baja frecuencia en Puerto Montt (27,1 %) y Maipú (13,9 %); la desconexión por instalaciones de terceros en Temuco (24,3 %), Antofagasta (21,6 %), Rancagua (18,2 %) y Coquimbo (17,2 %), y el blackout del sistema en Valparaíso (14,3 %). **Limitación:** la matriz incluye solo seis descripciones, así que sus filas no suman 100 %; los porcentajes no son tasas de fallas físicas ni de clientes interrumpidos.

7.4.11. Calidad de la información causal por comuna

Figura 14. *Disponibilidad y condición de la información causal en las 15 comunas prioritarias*



Fuente: Elaboración propia con Python (pandas y matplotlib) a partir de los informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.) y del Censo 2024 (INE, 2025). Generada en F2 §6.13.6; archivo `F2/figuras/F2_613_Figura_04_Calidad_Causal_Comunal.png`.

Interpretación técnica. En la mayoría de las comunas predomina la información causal no determinada, entre ellas Puente Alto, San Bernardo, Coquimbo, La Serena y Arica. Puerto Montt presenta la mayor participación de descripciones definitivas y la menor proporción sin causa determinada. **Consecuencias para el estudio:** con 1.109 de 1.834 informes sin causa determinada (60,47 %), los análisis causales de F3 deberán informar la cobertura de cada comuna. Estas diferencias reflejan la composición documental de los informes y no necesariamente una mayor capacidad de diagnóstico técnico en una comuna.

7.4.12. Denominador para comparar comunas (D-06)

F2 §6.13.7 calculó, como propuesta para F3, la tasa de informes no anulados por 100.000 habitantes-año (33 meses publicados = 2,75 años observados):

Tabla 30. *Conteo y tasa documental por 100.000 habitantes-año por comuna (propuesta D-06)*

Comuna	Población 2024	Informes no anulados	Ranking por conteo	Tasa por 100.000 hab.-año	Ranking por tasa
Antofagasta	401.096	503	1	45,60	1
Arica	241.653	161	2	24,23	2
Rancagua	257.744	141	4	19,89	3
Coquimbo	263.719	120	5	16,55	4
La Serena	250.141	101	6	14,68	5
Temuco	292.518	101	6	12,56	6
Valparaíso	284.938	97	8	12,38	7

Comuna	Población 2024	Informes no anulados	Ranking por conteo	Tasa por 100.000 hab.-año	Ranking por tasa
Puente Alto	568.086	150	3	9,60	8
San Bernardo	306.371	72	10	8,55	9
La Florida	374.836	82	9	7,95	10
Viña del Mar	334.871	67	11	7,28	11
Puerto Montt	277.040	54	13	7,09	12
Santiago	438.856	65	12	5,39	13
Las Condes	296.134	35	14	4,30	14
Maipú	503.635	35	14	2,53	15

Fuente: Elaboración propia a partir de F2 §6.13.7 (ejecución 25), con datos del Censo 2024 (INE, 2025) y informes de falla del Coordinador Eléctrico Nacional (CEN, s. f.).

Interpretación. El conteo no crece con la población (Spearman = −0,27; n = 15) y la tasa reordena el ranking en 10 de 15 comunas. La exposición documental parece depender más de la infraestructura eléctrica cercana que de la cantidad de habitantes; por eso la tasa se informa junto con el conteo. **Limitación:** el denominador ideal sería la cantidad de instalaciones del SEN o de clientes por comuna, que no forman parte de las fuentes actuales (F2 §6.13.7.1).

7.5. Archivos procesados

Tabla 31. *Conjuntos exportados por F2 en la carpeta data/processed/f2/*

Archivo	Registros	Columnas	Contenido
`01_cen_documental_procesado`	18.019	51	Informes con variables normalizadas y temporales
`02_cen_asociaciones_auditadas`	23.284	12	Vínculos informe–comuna homologados y auditados
`03_cen_informes_prioritarios`	1.834	51	Informes de las 15 comunas
`04_cen_fallas_comunas_integrado`	1.915	41	Vínculos prioritarios integrados (entrada de F3)
`05_cen_perfiles_15_comunas`	15	20	Perfil por comuna
`06_cen_recurrencia_causal_comunal`	181	7	Recurrencia de causas por comuna
`07_cen_validaciones_tecnicas`	40	5	Resultado de las 40 pruebas

Fuente: Elaboración propia a partir de F2 §6.15 (ejecuciones 27 y 28). Los siete archivos tienen SHA-256 coincidente con `manifest_f2.json`.

7.6. Conclusiones de la Fase 2

Las conclusiones registradas en F2 §6.16 se resumen así:

- Se conservaron los 18.019 informes originales y se construyeron 23.284 asociaciones de 16.874 informes con comuna, homologadas al 100 % con el maestro del INE.
- Las 15 comunas prioritarias reúnen 1.834 informes distintos y 1.915 asociaciones; 71 informes se vinculan a dos o más comunas.
- De los 1.834 informes, 954 están finalizados, 750 pendientes y 130 anulados; 708 declaran consumo no afectado, 1.104 consumo regulado, libre o mixto, y 22 no tienen clasificación.
- Hay 560 informes en 2024, 818 en 2025 y 456 entre enero y septiembre de 2026; febrero de 2025 concentra 282, y el 25 de febrero, 218.
- Las subestaciones representan el 70,28 % de los informes prioritarios, y la desconexión por instalaciones de terceros es la descripción causal específica más frecuente (243).
- Las limitaciones principales son 1.145 informes sin comuna, 880 informes prioritarios sin fecha de término y 1.109 sin causa determinada; los resultados no permiten calcular SAIDI, SAIFI, clientes

afectados ni energía no suministrada.

- Las 40 pruebas fueron aprobadas y la reproducibilidad se comprobó en un segundo equipo.

VIII. VINCULACIÓN DEL MAPA CONCEPTUAL CON EL AVANCE DEL PROYECTO

El mapa conceptual de la Formativa 1 se corrigió con la retroalimentación docente (issues #8–#13):

- se agregó la pregunta analítica;
- se agregó la etapa de obtención de los datos;
- todo el texto quedó en 11 pt o más.

El mapa se genera desde F1 (§9, ejecución 5), que verifica con `assert` que sus 114 textos tienen 11 pt o más y que 105 textos no desbordan su caja. Su concepto central es la exposición operacional documentada, y de él salen cinco ramas: **Problema**, **Ciclo del dato**, **Herramientas**, **Documentación** y **Repositorio**. Cada flecha se lee como una proposición (origen → verbo → destino); los enlaces cruzados muestran que las herramientas y la documentación acompañan cada etapa. La jerarquía, los conectores con verbo y los enlaces cruzados siguen a Novak y Cañas (2008) y a la guía de la Universidad de Chile (s. f.). El mapa se reproduce en la Figura 15, en una página horizontal, para conservar su tamaño real.

La tabla relaciona cada tipo de elemento del mapa con su implementación:

Tabla 32. *Correspondencia entre los elementos del mapa conceptual y su implementación*

Elemento del mapa	Tipo	Estado	Evidencia
Git y GitHub	Herramienta	Implementado	Historial con commits por integrante, PR #2–#6 y #14, issues #8–#13
Python `src/`, Jupyter, pandas y NumPy	Herramienta	Implementado	`src/` (3 módulos), F1 y F2
Pruebas `assert`	Herramienta	Implementado	6 pruebas en F1, 40 en F2 y 149 `assert`
matplotlib	Herramienta	Parcial	Mapa y figuras exploratorias; visualizaciones finales en F4
① Pregunta	Proceso	Implementado	F1 §3
② Obtención	Proceso	Implementado	`src/descargar_cen.py`, `docs/descargas_cen.csv`
③ Depuración	Proceso	Implementado	F2 §4–§5
④ Homologación	Proceso	Implementado	F2 §6.5–§6.7, `data/reference/`
⑤ Caracterizar	Proceso	Parcial	F2 §6.11–§6.13; indicadores finales en F3
⑥ Comunicar	Proceso	Parcial	Este informe; comunicación de resultados en F4
Retornos del ciclo	Flujo reproducible	Implementado	La depuración obligó a redefinir la pregunta (NYC 311 → CEN); la revisión de asociaciones pendientes devolvió a la homologación (equivalencias y validación multirregional, F2 §6.6.4–§6.6.5)
`requirements.txt`, `.venv` y manifiesto SHA-256	Flujo reproducible	Implementado	`src/trazabilidad.py`, `docs/verificacion_entorno.md`
Registro de decisiones y equivalencias	Decisión técnica	Implementado	`docs/decisiones.md` (D-01 a D-09)
Tasa documental por 100.000 habitantes	Decisión técnica	Propuesto	F2 §6.13.7 (D-06); cálculo final en F3
`data/raw`, `external`, `reference` y `processed`	Organización del repositorio	Implementado	Carpetas con su propio README
`F1/` y `F2/`	Estructura del notebook	Implementado	Un notebook por fase, con celdas narrativas por etapa

Fuente: Elaboración propia a partir del mapa conceptual (F1 §9), F1 §9.2 y el notebook F2.

Elementos implementados, pendientes y proyectados. Lo implementado coincide con lo que el mapa

proyectaba para F1 y F2: herramientas, obtención, depuración, homologación y un flujo reproducible. La validación de F2 lo comprueba. Lo pendiente (⑤ caracterizar, ⑥ comunicar y la tasa documental) sigue siendo pertinente, porque responde directamente a OE4 y OE5, que el plan asigna a F3 y F4:

- **Proyectado a F3:** indicadores comunales finales (tasa documental por 100.000 habitantes-año, informes con consumo afectado, recurrencia temporal y duración documental con mediana, percentiles y número de atípicos por comuna).
- **Proyectado a F4:** visualizaciones comparativas finales, hallazgos, conclusiones y recomendaciones, y la síntesis de los datos adicionales necesarios para medir impacto directo sobre usuarios.

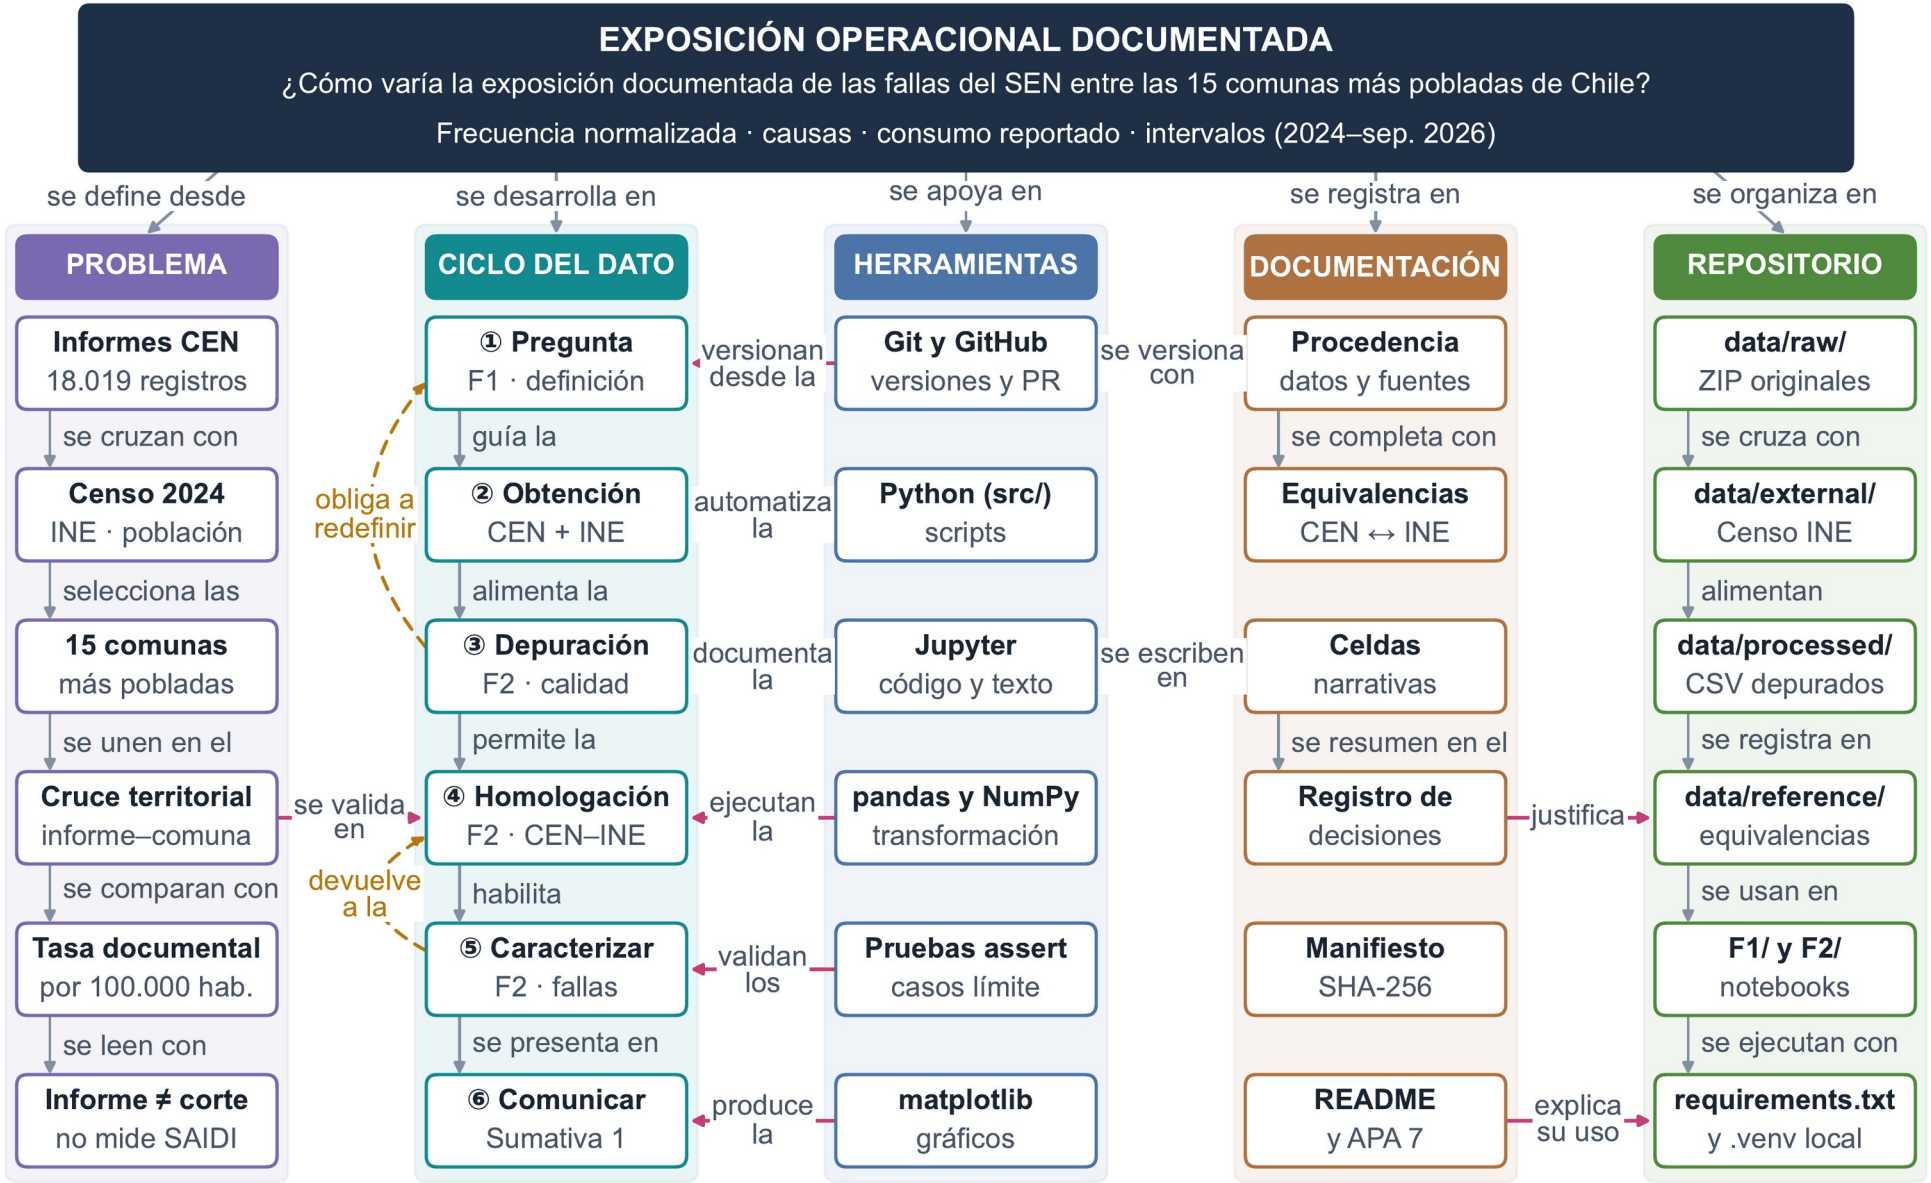
Justificación. Los dos retornos del mapa ocurrieron de verdad: el conjunto inicial se reemplazó tras la exploración, y la homologación se ajustó después de revisar las asociaciones pendientes.

Figura 15. *Mapa conceptual del proyecto: exposición operacional documentada de las 15 comunas más pobladas de Chile a fallas del SEN*

Fuente: Elaboración propia, generado por F1 §9 (ejecución 5); archivo `docs/mapa_conceptual_F1_impacto_comunal.pdf`. Estructura según Novak y Cañas (2008). El mapa se presenta en la página siguiente, en formato carta horizontal y a tamaño cercano al real (11 × 8,5 pulgadas), para conservar su texto en 11 pt.

MAPA CONCEPTUAL · ANÁLISIS TERRITORIAL DE FALLAS DEL SEN · GRUPO 7

FUENTES: informes del CEN (ene. 2024–sep. 2026) · Censo 2024 del INE



LEYENDA

Concepto central · Rama · Concepto (nombre y función) · ①–⑥ etapas del análisis · F1–F2 fases del proyecto

Relación: origen → verbo → destino · Enlace cruzado entre ramas · Retorno del ciclo (se itera)

IX. BIBLIOGRAFÍA

Barker, M., Chue Hong, N. P., Katz, D. S., Lamprecht, A.-L., Martinez-Ortiz, C., Psomopoulos, F., Harrow, J., Castro, L. J. G., Gruenpeter, M., Martinez, P. A., & Honeyman, T. (2022). Introducing the FAIR principles for research software. *Scientific Data, 9*, artículo 622. https://doi.org/10.1038/s41597-022-01710-x

Chacon, S., & Straub, B. (2014). *Pro Git* (2.ª ed.). Apress. https://git-scm.com/book/es/v2

Comisión Nacional de Energía. (2024). *Norma técnica de calidad de servicio para sistemas de distribución*. https://www.cne.cl/normativas/electrica/normas-tecnicas/ntcsdx2024/

Coordinador Eléctrico Nacional. (s. f.). *Desconexiones e intervenciones / informes de falla / limitaciones* [Conjunto de datos]. https://www.coordinador.cl/operacion/graficos/desconexiones-e-intervenciones/

Instituto Nacional de Estadísticas. (2025). *Resultados del Censo de Población y Vivienda 2024*. https://censo2024.ine.gob.cl/resultados/

Novak, J. D., & Cañas, A. J. (2008). *The theory underlying concept maps and how to construct and use them* (Technical Report IHMC CmapTools 2006-01 Rev 01-2008). Florida Institute for Human and Machine Cognition.

pandas development team. (s. f.-a). *pandas.to_datetime*. pandas documentation. https://pandas.pydata.org/docs/reference/api/pandas.to_datetime.html

pandas development team. (s. f.-b). *Working with missing data*. pandas documentation. https://pandas.pydata.org/docs/user_guide/missing_data.html

Python Software Foundation. (s. f.). *venv — Creation of virtual environments*. Python 3.13 documentation. https://docs.python.org/3.13/library/venv.html

Salinas, O. (2026a). *Limpieza y transformación de datos tabulares con Pandas* [Apunte]. Universidad Andrés Bello.

Salinas, O. (2026b). *Estructura profesional de un proyecto Python* [Apunte]. Universidad Andrés Bello.

Salinas, O. (2026c). *Tipos, variables, booleanos, condicionales, ciclos, funciones, módulos y excepciones en Python* [Apunte]. Universidad Andrés Bello.

Silva, M. K. da, Lopes, R. S., Fontana, M. E., & Almeida, J. K. B. de. (2025). A data-driven approach to maintenance-preventable causes of failure analysis in power distribution systems. *Brazilian Journal of Operations & Production Management, 22*(3), artículo 2702. https://doi.org/10.14488/BJOPM.2702.2025

Superintendencia de Electricidad y Combustibles. (s. f.). *Interrupciones eléctricas – SAIDI*. https://www.sec.cl/informe-sec-saidi/

Universidad de Chile. (s. f.). *¿Cómo hacer un mapa conceptual?* https://aprendizaje.uchile.cl/recursos-para-leer-escribir-y-hablar-en-la-universidad/profundiza/lectura/mapa/

Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology, 13*(6), e1005510. https://doi.org/10.1371/journal.pcbi.1005510

ANEXO A. DECLARACIÓN DE USO DE INTELIGENCIA ARTIFICIAL

El equipo usó un asistente de inteligencia artificial generativa (Claude, de Anthropic, mediante Claude Code) como apoyo para:

- revisar código;
- proponer las correcciones del feedback docente;
- redactar documentación y mensajes de commit;
- generar el mapa conceptual;
- estructurar este informe.

Todas las cifras provienen de la ejecución de los notebooks y de los archivos del repositorio. El equipo revisó el contenido, tomó las decisiones metodológicas (registradas en `docs/decisiones.md`) y es responsable de cada afirmación. Cada integrante debe poder explicar el código y las decisiones del proyecto.

ANEXO B. DETALLE DE LAS 40 PRUEBAS AUTOMATIZADAS DE F2

Tabla 33. *Pruebas automatizadas de F2: grupo, prueba, resultado y observación*

N.º	Grupo	Prueba	Estado	Observación
1	Normalizacion	Normalización de caracteres acentuados	Aprobada	La normalización reconoce caracteres acentuados.
2	Normalizacion	Coincidencia de región individual	Aprobada	Se reconoce una región individual válida.
3	Normalizacion	Reconocimiento de regiones múltiples	Aprobada	Se identifica la región oficial dentro de una zona multirregional.
4	Normalizacion	Rechazo de región no coincidente	Aprobada	No se asigna una coincidencia regional inexistente.
5	Normalizacion	Tratamiento de región faltante	Aprobada	Los valores nulos no generan coincidencias falsas.
6	Auditoria geografica	Coincidencia regional con denominaciones alternativas	Aprobada	Se reconoce una denominación regional equivalente.
7	Auditoria geografica	Detección de diferencia regional	Aprobada	Se identifica una incompatibilidad regional.
8	Auditoria geografica	Identificación de zona faltante	Aprobada	Se clasifica correctamente la ausencia de zona.
9	Auditoria geografica	Detección de denominación no reconocida	Aprobada	Se identifica una denominación regional desconocida.
10	Clasificacion operacional	Reconocimiento de estado válido	Aprobada	Se conserva una categoría administrativa válida.
11	Clasificacion operacional	Reconocimiento de consumo válido	Aprobada	Se conserva una clasificación de consumo reconocida.
12	Clasificacion operacional	Tratamiento de valor nulo	Aprobada	Los valores nulos se clasifican explícitamente.
13	Clasificacion operacional	Tratamiento de cadena vacía	Aprobada	Las cadenas vacías se identifican como datos faltantes.
14	Clasificacion operacional	Detección de categoría desconocida	Aprobada	Las categorías no previstas se identifican para revisión.
15	Conversion temporal	Conversión de fecha ISO	Aprobada	Se reconoce una fecha con formato ISO.
16	Conversion temporal	Conversión de fecha día/mes/año	Aprobada	Se reconoce una fecha con formato día/mes/año.
17	Conversion temporal	Identificación de fecha inexistente	Aprobada	Las fechas inexistentes se clasifican como inválidas.
18	Conversion temporal	Tratamiento de fecha faltante	Aprobada	Las fechas faltantes se conservan como NaT.
19	Conversion temporal	Detección de intervalo negativo	Aprobada	Se reconoce un término anterior a la perturbación.
20	Control excepciones	Rechazo de integración con claves duplicadas	Aprobada	Pandas impide una integración many_to_one inconsistente.
21	Integridad documental	Conservación de informes originales	Aprobada	Se conservaron los 18.019 informes del CEN.
22	Integridad documental	Unicidad de informes originales	Aprobada	Los informes poseen identificadores únicos y completos.
23	Integridad documental	Conservación de base temporal	Aprobada	La transformación temporal no eliminó informes.
24	Integridad documental	Conservación de columnas originales	Aprobada	Las variables originales permanecen intactas.
25	Integridad territorial	Conservación de asociaciones	Aprobada	Se conservaron las 23.284 asociaciones.
26	Integridad territorial	Ausencia de asociaciones duplicadas	Aprobada	No existen relaciones informe-comuna duplicadas.
27	Integridad territorial	Completitud de homologación comunal	Aprobada	Todas las asociaciones tienen código comunal oficial.
28	Integridad territorial	Consistencia geográfica	Aprobada	Todas las asociaciones presentan coincidencia regional.
29	Conjunto prioritario	Cantidad de comunas prioritarias	Aprobada	La selección contiene 15 comunas.
30	Conjunto prioritario	Unicidad de códigos comunales	Aprobada	No existen comunas prioritarias duplicadas.
31	Conjunto prioritario	Conservación de informes prioritarios	Aprobada	Se identificaron 1.834 informes distintos.
32	Conjunto prioritario	Conservación de asociaciones prioritarias	Aprobada	Se conservaron 1.915 asociaciones prioritarias.

N.º	Grupo	Prueba	Estado	Observación
33	Conjunto prioritario	Consistencia del conjunto cruzado	Aprobada	La integración técnica conserva las asociaciones.
34	Calidad temporal	Validez de fechas de perturbación	Aprobada	Se reconocieron las fechas de perturbación originales.
35	Calidad temporal	Identificación de fechas de término faltantes	Aprobada	Se identificaron 7.214 informes sin fecha de término.
36	Calidad temporal	Ausencia de intervalos negativos válidos	Aprobada	Los intervalos utilizados no presentan valores negativos.
37	Consistencia causal	Conservación de informes analizados	Aprobada	El análisis causal conserva los informes únicos.
38	Consistencia causal	Identificación de causas no determinadas	Aprobada	Se identificaron 1.109 informes sin causa determinada.
39	Consistencia causal	Conservación de informes con descripción causal	Aprobada	Se conservaron los 725 informes con descripción específica.
40	Consistencia causal	Coherencia de causas definitivas	Aprobada	Se identificaron 385 informes con descripción definitiva.

Fuente: Elaboración propia a partir de la salida de F2 §6.14 (ejecución 26) y del archivo `07_cen_validaciones_tecnicas.csv`. Las observaciones de las pruebas 2 a 5 se transcriben de la tabla de resultados del notebook.

ANEXO C. PERFIL DOCUMENTAL POR COMUNA PRIORITARIA

Resultados del análisis cruzado de F2 §6.13 (ejecución 22). Los porcentajes se calculan sobre las asociaciones de cada comuna.

Tabla 34. *Perfil documental por comuna: instalación, causa, consumo y 25 de febrero de 2025*

Comuna	Asociaciones	% subestación	% causas presuntas	% con categoría de consumo afectado	Informes del 25-02-2025 (%)
Puente Alto	157	57,32	76,43	60,51	14 (8,92)
Maipú	36	97,22	80,56	77,78	3 (8,33)
Santiago	73	84,93	65,75	65,75	4 (5,48)
Antofagasta	547	72,21	57,40	59,78	82 (14,99)
La Florida	88	45,45	72,73	31,82	5 (5,68)
Viña del Mar	68	82,35	85,29	83,82	11 (16,18)
San Bernardo	75	77,33	80,00	74,67	9 (12,00)
Las Condes	38	84,21	84,21	73,68	3 (7,89)
Temuco	107	68,22	78,50	57,94	14 (13,08)
Valparaíso	105	79,05	78,10	73,33	19 (18,10)
Puerto Montt	59	84,75	49,15	69,49	4 (6,78)
Coquimbo	128	62,50	82,03	40,62	15 (11,72)
Rancagua	148	51,35	73,65	43,92	19 (12,84)
La Serena	106	79,25	83,96	67,92	9 (8,49)
Arica	180	76,11	70,56	77,22	26 (14,44)

Fuente: Elaboración propia a partir de F2 §6.13.4 (ejecución 22).