Universidad Andrés Bello

Magíster en Ciencia de Datos e Inteligencia Artificial
MCDI500 · Programación para la Ciencia de Datos

EVALUACIÓN SUMATIVA 1 · FASES 1 Y 2

Informe técnico: implementación inicial del entorno reproducible, exploración y procesamiento inicial de los datos

Proyecto: Exposición operacional documentada de las 15 comunas más pobladas de Chile a las fallas del Sistema Eléctrico Nacional (2024–2026)

Grupo 7
Jairo Barraza Salazar
Javier Huamanni Barrera
Jean Salas Meneses
Pavel Chávez San Martín

Docente: Dr. Omar Salinas Silva

Fecha: 8 de noviembre de 2026

Repositorio: https://github.com/jeanpaulsalasmeneses-lab/Proyecto_MCDI500

Índice

1. Introducción y contextualización 4

1.1. Entorno y antecedentes 4

1.2. Situación que origina el análisis 4

1.3. Problema y propósito 4

1.4. Justificación técnica 4

1.5. Conexión con las fases del proyecto 5

2. Definición de la problemática y objetivos 5

2.1. Problemática delimitada 5

2.2. Pregunta analítica 5

2.3. Objetivos 5

2.4. Alcance 6

2.5. Restricciones 6

2.6. Supuestos 7

2.7. Correspondencia con lo desarrollado en F1 y F2 7

3. Aplicación de herramientas científicas 7

4. Reproducibilidad técnica 8

5. Control de versiones 9

6. Documentación del proceso 10

6.1. Flujo de trabajo completo 10

6.2. Registro de decisiones técnicas 10

6.3. Enfoques descartados 11

6.4. Fragmentos de código comentados 11

7. Repositorio GitHub 12

8. Codificación funcional 13

9. Preprocesamiento y transformación del dataset 13

9.1. Diagnóstico previo 13

9.2. Roles de las variables y transformación según el rol (D-09) 14

9.3. Valores faltantes: patrón, alternativas y decisión (D-05) 14

9.4. Valores atípicos (D-08) 15

9.5. Normalización y homologación territorial (D-02) 15
9.6. Normalización por población (D-06) 16
9.7. Conjunto resultante 16
10. Validación técnica y verificación del código 16
11. Notebook F1: definición y entorno 17
12. Notebook F2: exploración y preprocesamiento 17
13. Vinculación del mapa conceptual con el avance 18
14. Referencias 21
Anexo A. Declaración de uso de inteligencia artificial 22

1. Introducción y contextualización

1.1. Entorno y antecedentes

El Sistema Eléctrico Nacional (SEN) abastece a la mayor parte de la población de Chile. El Coordinador Eléctrico Nacional (CEN) coordina su operación y publica cada mes los **informes de falla** de las instalaciones de generación y transmisión, dentro del conjunto *Desconexiones e intervenciones / informes de falla / limitaciones* (Coordinador Eléctrico Nacional [CEN], s. f.). Cada informe identifica la instalación, la causa declarada, las fechas de perturbación y término, el consumo reportado como afectado y, en el campo `Comuna`, uno o más territorios mencionados.

Este proyecto usa las **33 publicaciones mensuales** de enero de 2024 a septiembre de 2026, que suman **18.019 informes y 28 variables originales**, y la tabla oficial de población comunal del **Censo 2024** (Instituto Nacional de Estadísticas [INE], 2025).

1.2. Situación que origina el análisis

Las comparaciones territoriales de calidad de suministro en Chile usan indicadores regulatorios como SAIDI y SAIFI. Estos se calculan con **clientes interrumpidos y tiempos efectivos de interrupción** (Comisión Nacional de Energía [CNE], 2024; Superintendencia de Electricidad y Combustibles [SEC], s. f.). Los informes del CEN describen otra cosa: **fallas de instalaciones del sistema**, sin número de clientes. Hoy no existe una vista comunal y reproducible de esos informes, por cuatro razones:

- la información está repartida en 33 archivos comprimidos;
- la comuna viene como texto libre;
- un mismo informe puede mencionar varias comunas separadas por «|»;
- los nombres no coinciden siempre con los nombres oficiales del INE.

1.3. Problema y propósito

El problema es **medir y comparar la exposición operacional documentada** de las 15 comunas más pobladas de Chile a las fallas del SEN. Definimos esa exposición como la frecuencia, la recurrencia y la duración de los informes de falla del CEN que mencionan a cada comuna. **No equivale a interrupciones efectivas de suministro**, porque que un informe mencione una comuna no prueba que sus clientes quedaran sin luz.

Este informe documenta el avance de las **Fases 1 y 2**: la definición del problema, el entorno reproducible y el pipeline de obtención, exploración, limpieza, transformación y validación de los datos. Cada cifra que aparece aquí se puede verificar en los notebooks F1 y F2 y en el repositorio.

1.4. Justificación técnica

El problema requiere programación por cinco razones:

- **Volumen y dispersión:** 33 archivos que hay que leer, validar y consolidar con trazabilidad hasta la fila de origen.
- **Normalización textual:** 320 denominaciones comunales distintas que deben homologarse con los 346 códigos oficiales del INE.

- **Relación muchos a muchos:** 16.874 informes con comuna generan 23.284 vínculos informe–comuna.
- **Validación sistemática:** 40 pruebas automatizadas en F2 y verificaciones de integridad en cada etapa.
- **Reproducibilidad:** otro equipo debe poder repetir todo el proceso y obtener los mismos archivos. En hojas de cálculo eso no se puede garantizar.

1.5. Conexión con las fases del proyecto

Fase	Aporte al proyecto	Estado
F1. Definición y entorno	Problema, pregunta, objetivos, alcance, entorno reproducible y mapa conceptual	Desarrollada (este informe)
F2. Exploración y preprocesamiento	Obtención, diagnóstico de calidad, limpieza, homologación CEN–INE, transformación y validación	Desarrollada (este informe)
F3. Análisis	Indicadores comunales: tasa de exposición, recurrencia, duración y consumo reportado	Proyectada
F4. Visualización y comunicación	Visualizaciones comparativas, hallazgos, conclusiones y recomendaciones	Proyectada

2. Definición de la problemática y objetivos

2.1. Problemática delimitada

Se analiza **cómo se distribuyen los informes de falla del SEN** publicados por el CEN entre enero de 2024 y septiembre de 2026 **entre las 15 comunas más pobladas de Chile**, según el Censo 2024. La unidad de registro es el **informe de falla** (`id_falla`), y la unidad de comparación es la **comuna**. La relación entre ambas es el **vínculo informe–comuna**: un informe que menciona tres comunas genera tres vínculos, pero sigue siendo un solo informe.

2.2. Pregunta analítica

> *¿Cómo se distribuye la exposición operacional documentada a fallas del Sistema Eléctrico Nacional entre las 15 comunas más pobladas de Chile (Censo 2024), entre enero de 2024 y septiembre de 2026, medida como la frecuencia de informes del CEN en relación con su población, la recurrencia temporal y la duración documental de esos informes, y qué parte de esa exposición corresponde a eventos con afectación de consumo reportada?*

2.3. Objetivos

Objetivo general. Analizar comparativamente la exposición operacional documentada a eventos de falla del SEN en las 15 comunas de mayor población censada de Chile, con los informes publicados entre enero de 2024 y septiembre de 2026. Para ello se usan procedimientos reproducibles de ciencia de datos que caracterizan la frecuencia, la recurrencia, la afectación de consumo reportada y la duración documental válida, con sus límites de interpretación explícitos.

Objetivo específico	Indicador de logro	Fase
OE1. Integrar las 33 publicaciones del CEN con la tabla oficial del Censo 2024, conservando identificadores y procedencia	33 de 33 meses consolidados; 346 comunas INE con código único	F1–F2
OE2. Depurar los 18.019 registros y vincularlos con códigos comunales oficiales, resolviendo las listas multicomuna	Porcentaje de vínculos homologados con el INE (logrado: 100 %)	F2
OE3. Seleccionar las 15 comunas más pobladas y caracterizar la cobertura de sus informes	Lista reproducible de 15 comunas; informes y vínculos asociados (1.834 y 1.915)	F2
OE4. Cuantificar por comuna informes únicos, informes con consumo afectado, recurrencia temporal y duración documental válida	Cuatro dimensiones por comuna, con criterios de inclusión explícitos	F3
OE5. Visualizar, contrastar y comunicar los resultados y sus límites de medición	Al menos 4 visualizaciones, 5 hallazgos, 3 conclusiones y 2 recomendaciones	F3–F4

2.4. Alcance

Son **decisiones del equipo**:

- **Se aborda:**
  - las 15 comunas con mayor población censada en 2024, sin importar a qué región pertenezcan;
  - los informes de falla del CEN publicados entre enero de 2024 y septiembre de 2026;
  - indicadores descriptivos de exposición documental.
- **Queda fuera:**
  - indicadores regulatorios (SAIDI, SAIFI, clientes-hora interrumpidos);
  - energía no suministrada y pérdidas económicas;
  - modelos predictivos;
  - las solicitudes de trabajo y las limitaciones, que vienen en los mismos ZIP del CEN pero no son informes de falla;
  - el resto de las 331 comunas, salvo como contexto.

2.5. Restricciones

Son **condiciones impuestas** por los datos, el tiempo o las herramientas:

- **Datos:** los informes no incluyen el número de clientes afectados. El 40,04 % no tiene fecha efectiva de término, y el 6,35 % no tiene comuna. Las causas vienen parcialmente en texto libre, y el 60,47 % de los informes prioritarios no tiene una causa determinada.
- **Cobertura temporal:** 2026 tiene solo 9 meses publicados, así que las comparaciones anuales deben normalizarse por tiempo observado.
- **Tiempo:** el proyecto se desarrolla en tres semanas; esta entrega corresponde a la primera.

- **Herramientas:** se usa el ecosistema del curso (Python 3.13, pandas, NumPy, matplotlib, Jupyter, Git y GitHub). No se usan sistemas de información geográfica.

2.6. Supuestos

1. Una mención de comuna en un informe del CEN indica **exposición documental** de esa comuna, **no** una interrupción de sus clientes.
2. Los nombres de comuna del CEN se pueden homologar con el INE cuando la correspondencia es unívoca y la región declarada en `Zona Afectada` coincide.
3. La población censada es un **normalizador territorial** válido para comparar comunas de distinto tamaño (D-06). No mide clientes, consumo ni infraestructura.
4. La fecha efectiva de término marca el **cierre administrativo** del informe, no necesariamente la reposición del suministro a cada cliente.
5. El conjunto publicado por el CEN es la fuente oficial disponible. Su completitud no se puede auditar contra otra fuente.

2.7. Correspondencia con lo desarrollado en F1 y F2

Elemento de la formulación	Dónde se desarrolla
Problema, pregunta, objetivos, alcance y supuestos	F1 §1–§6
OE1: integración CEN–INE	`src/descargar_cen.py`, `src/consolidar_fallas_2024_2026.py`, F2 §6.5
OE2: depuración y homologación	F2 §4–§6.7 y `data/reference/`
OE3: selección y cobertura de las 15 comunas	F2 §6.5.2 y §6.8
OE4 y OE5: indicadores y comunicación	Propuestas en F2 §6.10.5, §6.10.6 y §6.13.7; se calculan en F3 y F4

3. Aplicación de herramientas científicas

Cada herramienta resuelve un problema concreto del proyecto:

Herramienta	Propósito en este proyecto	Dónde se usa
pandas	Leer CSV y Excel, normalizar, cruzar tablas (`merge` con `validate`), agrupar y exportar	F1 §8.2; F2 en todas las etapas; `src/`
NumPy	Base numérica de pandas y valores faltantes (`np.nan`); semilla aleatoria	F2 y `src/trazabilidad.py`
matplotlib	Mapa conceptual y figuras exploratorias guardadas en `F2/figuras/`	F1 §9 y F2 §6.11–§6.13
Jupyter	Notebooks con código, salidas y narrativa, uno por fase	`F1/`, `F2/`

Herramienta	Propósito en este proyecto	Dónde se usa
Git y GitHub	Versionar cada cambio, revisar por pull request y registrar decisiones en issues	Historial del repositorio
venv y requirements.txt	Aislar el entorno y fijar las versiones exactas	`.venv/`, `requirements.txt`

Las librerías se usan **dentro de funciones**, no en celdas sueltas. Algunos ejemplos son `normalizar_comuna()`, `auditar_asociacion()`, `comparar_alternativas()` y `perfil_variable()` en F2, y `verificar_dataset()` en F1.

La integración del ecosistema se ve en tres señales:

1. **Verificación del entorno al inicio** de cada notebook (F1 §8.1 y §8.1.1, F2 §0).
2. **Rutas relativas**, porque la raíz del proyecto se ubica automáticamente.
3. **Commit y rama** en que se ejecutó cada notebook, impresos por `src/trazabilidad.py`.

4. Reproducibilidad técnica

- **Entorno virtual:** `.venv` creado con `venv`, de la biblioteca estándar de Python (Python Software Foundation, s. f.). Los notebooks fallan a propósito si el kernel no es el del entorno virtual.
- **Dependencias:** `requirements.txt` fija **107 paquetes con versión exacta**. `pywinpty` lleva el marcador `sys_platform == "win32"` y solo se instala en Windows.
- **Verificación componente por componente:** `src/trazabilidad.py` compara cada dependencia declarada con la instalada y detiene el notebook si alguna no coincide. En Linux el resultado es **106 de 106** (107 en Windows).
- **Rutas relativas y semilla:** no hay rutas absolutas en el código. La semilla está fija en 2024, aunque el pipeline no usa procesos aleatorios.
- **Integridad de las salidas.** Siguiendo prácticas de computación científica reproducible (Wilson et al., 2017), F2 exporta siete archivos con su SHA-256 en `data/processed/f2/manifest_f2.json` y comprueba que coincidan (§6.15.5). Se agregó `.gitattributes` (`*.csv -text`) porque Git en Windows cambiaba los saltos de línea de los CSV al hacer commit, y eso rompía los hashes en otro equipo (D-04).

Comprobación en un segundo equipo. La verificación está registrada en `docs/verificacion_entorno.md`:

- Se clonó el repositorio en una carpeta limpia de **Linux** (Python 3.13), sin los datos originales, y se ejecutaron F1 y F2 completos sin errores. Los **7 de 7** archivos exportados resultaron idénticos byte a byte.
- Los consolidados también se reconstruyeron **desde la fuente original**: se descargaron de nuevo los 33 ZIP con `src/descargar_cen.py`, se ejecutó la consolidación y el contenido resultó idéntico (18.019 registros, ninguna celda distinta).
- El mismo procedimiento quedó documentado para la verificación en Windows.

5. Control de versiones

Convención de commits. Prefijo y descripción en español:

Prefijo	Uso
`feat:`	Funcionalidad o análisis nuevo
`fix:`	Corrección
`docs:`	Documentación
`data:`	Cambios en los datos
`build:`	Entorno y dependencias
`merge:`	Integración de ramas

Los mensajes explican **qué cambió y por qué**, y citan el issue o el criterio de la rúbrica que resuelven (Chacon y Straub, 2014).

Ramas y pull requests. Los cambios de mayor alcance se integraron mediante pull request:

PR	Contenido
#2	Ajuste del texto del problema
#3	Reproducibilidad: datos, `.gitignore` y dependencias
#4–#6	Mapa conceptual y entrega de la Formativa
#14	Correcciones del feedback de la Formativa
Este avance	Brechas de la rúbrica de la Sumativa

Issues. El feedback docente de la Formativa se convirtió en seis issues (#8–#13), uno por punto, que los commits cierran con `Closes #n`.

Contribuciones por integrante. Commits identificables en el historial al momento de generar este informe (commit `bc2541b`):

Integrante	Commits (sin merges)
Jairo Barraza Salazar	12
Javier Huamanni Barrera	0
Jean Salas Meneses	22
Pavel Chávez San Martín	23
Total	**57**

Mejora pendiente. Parte del desarrollo de F2 se subió directamente a la rama principal, sin pull request. Desde la Fase 3, todo cambio entra por PR con revisión de otro integrante.

6. Documentación del proceso

6.1. Flujo de trabajo completo

Etapa	Entrada	Proceso	Salida
0. Obtención	Portal del CEN y Censo 2024	`src/descargar_cen.py` descarga y verifica los 33 ZIP; el Excel del INE se descarga con su SHA-256	`data/raw/*.zip`, `docs/descargas_cen.csv`, `data/external/`
1. Consolidación	33 ZIP	`src/consolidar_fallas_2024_2026.py`: lee solo el informe de fallas y agrega trazabilidad (ZIP, CSV, fila)	`data/processed/cen_fallas_2024_2026_{publicaciones,eventos}.csv`
2. Definición	Consolidado	F1: verificación estructural sin transformar, pruebas iniciales y mapa	Diagnóstico de factibilidad y mapa
3. Exploración y calidad	Consolidado	F2 §1–§4: dimensiones, tipos, nulos, duplicados y roles	Diagnóstico y `docs/diccionario_variables.csv`
4. Limpieza y normalización	Consolidado	F2 §5: claves de comuna, separación de listas, estados y consumo	23.284 vínculos informe–comuna
5. Homologación	Vínculos e INE	F2 §6.5–§6.7: maestro de 346 comunas y equivalencias de `data/reference/`	100 % homologado; `data/processed/homologacion/`
6. Transformación	Vínculos homologados	F2 §6.8–§6.10: 15 comunas, variables operacionales y temporales, faltantes y atípicos	Informes y vínculos prioritarios
7. Caracterización	Conjunto prioritario	F2 §6.11–§6.13: visualizaciones, causas y denominador	Perfiles comunales y figuras
8. Validación y exportación	Todo lo anterior	F2 §6.14–§6.15: 40 pruebas y exportación con SHA-256	7 CSV y `manifest_f2.json`

6.2. Registro de decisiones técnicas

Cada decisión tiene su entrada en `docs/decisiones.md`, con contexto, evidencia, alternativas descartadas y motivo:

Decisión	Resumen	Impacto medido
D-01	Versionar `data/processed/` y no `data/raw/`	Un clon limpio corre F1 y F2 sin descargar nada

Decisión	Resumen	Impacto medido
D-02	Equivalencias CEN ↔ INE en archivos versionados	156 vínculos homologados por 4 equivalencias; 0 sin homologar
D-03	«Sobreestimar» en lugar de «inflar»	Precisión en la redacción del doble conteo
D-04	CSV sin conversión de saltos de línea	SHA-256 idénticos entre Windows y Linux
D-05	Duración solo con informes finalizados	954 de 1.834 informes prioritarios tienen duración válida
D-06	Tasa por 100.000 habitantes-año para comparar	10 de 15 comunas cambian de posición respecto del conteo
D-07	Título y pregunta alineados con el criterio poblacional	Coherencia entre F1, F2, README e informe
D-08	Conservar los atípicos y resumir con la mediana	Eliminarlos movería la mediana un −17,5 %
D-09	Rol y selección de las 28 variables; casting a `category`	−98,4 % de memoria en las categóricas, sin cambiar valores

6.3. Enfoques descartados

Enfoque	Por qué se descartó
Conjunto inicial NYC 311 (reclamos de alumbrado público)	Sin vínculo territorial chileno
Contar como informes distintos las menciones a varias comunas	Sobreestima la exposición
Homologación aproximada automática (*fuzzy matching*)	Podría unir comunas distintas con nombres parecidos
Imputar las fechas de término faltantes	Inventaría cierres que no ocurrieron (D-05)
Eliminar los atípicos	Borraría eventos documentados reales (D-08)
One-hot encoding	No hay modelos que lo requieran (D-09)

6.4. Fragmentos de código comentados

La clave de comparación de comunas (F2 §5) elimina tildes y diferencias de mayúsculas **sin modificar el dato original**:

```
def normalizar_comuna(valor):
    texto = limpiar_texto(valor)        # espacios y vacíos -> NA
    if pd.isna(texto):
        return pd.NA
    # Separa cada letra de su tilde y descarta la tilde.
    texto = unicodedata.normalize("NFKD", texto)
    texto = "".join(
        c for c in texto if not unicodedata.combining(c)
    )
    return texto.upper()      # "Viña del Mar" -> "VINA DEL MAR"
```

La comparación de alternativas para los atípicos (F2 §6.10.6) trabaja sobre **copias** y mide el efecto de cada tratamiento antes de decidir:

```
def comparar_alternativas(serie):
    _, _, limite = limites_iqr(serie)      # Q3 + 1,5 * IQR
    p99 = serie.quantile(0.99)
    alternativas = {                       # siempre sobre copias
        "a) conservar todo": serie.copy(),
        "b) eliminar atípicos": serie[serie.le(limite)].copy(),
        "c) acotar al p99": serie.clip(upper=p99),
    }
    return pd.DataFrame(
        {n: resumen_duracion(s) for n, s in alternativas.items()}
    ).T
```

7. Repositorio GitHub

Repositorio: **https://github.com/jeanpaulsalasmeneses-lab/Proyecto_MCDI500**

```
Proyecto_MCDI500/
├── F1/F1_Definición.ipynb       Fase 1: problema, entorno, mapa
├── F2/
│   ├── F2_Exploracion_y_Preprocesamiento.ipynb
│   └── figuras/                 figuras exportadas por F2
├── src/
│   ├── descargar_cen.py         obtención de los 33 ZIP del CEN
│   ├── consolidar_fallas_2024_2026.py   ZIP -> CSV
│   └── trazabilidad.py          entorno, versiones, commit
├── data/
│   ├── raw/        ZIP originales (se descargan, no se suben)
│   ├── external/   Censo 2024 del INE (URL y SHA-256)
│   ├── reference/  equivalencias CEN <-> INE
│   └── processed/  consolidados, salidas de F2, homologación
├── docs/           fuentes, decisiones, diccionario, entregas
├── requirements.txt   107 dependencias con versión exacta
└── README.md          descripción e instrucciones
```

El `README.md` describe el proyecto, la estructura, las dependencias y cómo ejecutar cada notebook en Windows y en Linux o macOS. También explica cómo reconstruir los datos desde la

fuente original. Cada carpeta de datos tiene su propio `README.md` con su origen, en línea con los principios FAIR para software de investigación: código y datos localizables, accesibles y reutilizables (Barker et al., 2022). La estructura sigue la separación entre datos originales, externos y procesados que recomienda el material del curso (Salinas, 2026b).

8. Codificación funcional

Componente	Funciones	Ejemplos
F1	13	`localizar_proyecto`, `verificar_dataset`, `separar_comunas`, `consumo_reportado`
F2	30	`normalizar_comuna`, `crear_clave_region`, `auditar_asociacion`, `patron_fecha_termino`, `comparar_alternativas`, `perfil_variable`
`src/`	9	`descargar`, `zip_valido`, `verificar_dependencias`, `estado_git`, `informe_entorno`

- **Un propósito por función:** cada una recibe parámetros y devuelve un resultado. Por ejemplo, `limites_iqr(serie, factor=1.5)` devuelve los límites y `resumen_duracion(serie)` los estadísticos.
- **Estructuras de control en lugar de bloques repetidos:** F2 tiene 45 bucles y 69 condicionales. Recorre los 33 períodos, los dos universos de análisis y las 28 variables, en vez de repetir código por columna (Salinas, 2026c).
- **Copias explícitas:** F2 usa `.copy()` en 31 puntos, para que una transformación no altere el conjunto original (Salinas, 2026a).
- **Flujo verificable:** cada etapa imprime sus conteos antes y después, y los `merge` declaran su cardinalidad (`validate="many_to_one"`).

Limitación declarada. Parte de F2 todavía está escrita como celdas procedurales extensas. En F3, las funciones reutilizables de normalización y homologación se trasladarán a `src/` para importarlas en lugar de redefinirlas.

9. Preprocesamiento y transformación del dataset

9.1. Diagnóstico previo

El consolidado tiene **18.019 registros y 40 variables**: 28 originales y 12 de procedencia y derivadas. No hay identificadores duplicados: cada `id_falla` aparece una sola vez en las 33 publicaciones. Las variables con más faltantes son:

Variable	Faltantes	%
Elemento(s)	11.460	63,60
Distribuidoras Afectadas	11.210	62,21
SubEstación	9.148	50,77
Fecha Efectiva Fin	7.214	40,04

Variable	Faltantes	%
Causa Definitiva	2.153	11,95
Comuna	1.145	6,35
Zona Afectada	1.092	6,06
Consumo	287	1,59

9.2. Roles de las variables y transformación según el rol (D-09)

Las 28 variables originales tienen un **rol asignado**: identificador, nominal, territorial, fecha, texto libre o procedencia. Cada una tiene también una decisión justificada, publicada en `docs/diccionario_variables.csv`:

- 10 se analizan;
- 6 se conservan para análisis propuestos en F3;
- 11 se descartan del análisis, aunque quedan en los archivos para mantener la trazabilidad;
- 1 es de procedencia.

La selección **coincide en 25 de 28 columnas** con la propuesta de depuración que hizo Jairo Barraza (documento interno del equipo, issue #7). Las tres diferencias se resolvieron con evidencia:

- `Estado` explica todos los faltantes de la fecha de término;
- `Tipo Causa` distingue la causa presunta de la definitiva;
- `Causa Definitiva` es la base de la recurrencia causal.

Transformaciones según el rol:

- **Categóricas:** casting a `category`. Reduce la memoria un **98,4 %** (de 6,93 a 0,11 MB) sin cambiar ningún valor, comprobado con `assert`. No se aplica one-hot, porque no hay modelos, ni orden ordinal, porque ninguna categoría tiene un orden natural.
- **Fechas:** conversión a `datetime` en UTC (pandas development team, s. f.-a).
- **Texto territorial:** normalización a claves comparables.

9.3. Valores faltantes: patrón, alternativas y decisión (D-05)

Antes de decidir se midió el patrón de la fecha de término faltante (F2 §6.10.5). **No es aleatorio: lo explica por completo el estado administrativo.**

Estado	Con fecha de término	Sin fecha de término
Finalizado	10.802	0
Pendiente	0	6.138
Anulado	3	1.076

Se compararon cuatro alternativas:

Alternativa	Evaluación
Imputar la mediana	Crearía cierres que no ocurrieron
Usar la fecha estimada de retorno	Es una estimación, no un cierre
Usar la fecha de publicación	Mide un trámite, no el evento
Calcular la duración solo con informes finalizados	**Elegida**

Los pendientes cuentan para la frecuencia, pero no para la duración, y los anulados se excluyen de los indicadores (pandas development team, s. f.-b).

Impacto declarado. En 2025, el 51 % de los informes prioritarios sigue pendiente. La causa principal es el apagón del 25 de febrero de 2025: el 83,5 % de sus 218 informes prioritarios está pendiente, frente al 39 % del resto del año. Por eso **la duración subrepresenta ese evento**, y las conclusiones de F3 deben decirlo.

9.4. Valores atípicos (D-08)

Con la regla IQR, **69 de 954** intervalos de informes finalizados prioritarios son atípicos (7,2 %), y el máximo llega a 1.073 horas. Las tres alternativas se compararon midiendo su efecto:

Alternativa	Media	Cambio en la media	Mediana	Cambio en la mediana
Conservar todo	6,65 h	—	1,60 h	—
Eliminar atípicos	2,52 h	−62,1 %	1,32 h	−17,5 %
Acotar al p99	3,74 h	−43,8 %	1,60 h	0,0 %

Decisión. Se conservan todos los intervalos, porque son eventos reales con fechas válidas, y la duración se resume con **mediana y percentiles**. La mediana no cambia al acotar los extremos, así que es pertinente para comparar comunas (OE4). Como toda medida robusta, sacrifica sensibilidad a los eventos largos. Por eso, en F3 cada comuna informará también cuántos de sus intervalos son atípicos.

9.5. Normalización y homologación territorial (D-02)

Separar el campo `Comuna` por «|» produjo **23.284 vínculos** de 16.874 informes, sin vínculos duplicados. La homologación con el maestro del INE (346 comunas) tuvo tres pasos:

Paso	Vínculos homologados	% acumulado
Coincidencia exacta de la clave normalizada	23.128	99,33
Equivalencias con validación regional	128	99,88
Equivalencias con validación multirregional	28	**100,00**

Las cuatro equivalencias (Llay Llay, San Vicente de Tagua Tagua, Treguaco y Paiguano) viven en `data/reference/equivalencias_comunas.csv`. Ninguna corresponde a las 15 comunas analizadas.

9.6. Normalización por población (D-06)

Para comparar comunas de distinto tamaño, la exposición se expresa como **informes no anulados por 100.000 habitantes-año**. Los años observados son 33 meses / 12 = 2,75. El conteo absoluto no crece con la población (Spearman = −0,27), y al pasar a la tasa **10 de las 15 comunas cambian de posición**: por ejemplo, Puente Alto baja del 3.º al 8.º lugar. La tasa se informa siempre junto con el conteo, y se declara que el resultado depende del denominador.

9.7. Conjunto resultante

Archivo (`data/processed/f2/`)	**Registros**	**Columnas**	**Contenido**
01_cen_documental_procesado	18.019	51	Informes con variables normalizadas y temporales
02_cen_asociaciones_auditadas	23.284	12	Vínculos informe–comuna homologados y auditados
03_cen_informes_prioritarios	1.834	51	Informes de las 15 comunas
04_cen_fallas_comunas_integrado	1.915	41	Vínculos prioritarios integrados (entrada de F3)
05_cen_perfiles_15_comunas	15	20	Perfil por comuna
06_cen_recurrencia_causal_comunal	181	7	Recurrencia de causas por comuna
07_cen_validaciones_tecnicas	40	5	Resultado de las 40 pruebas

Coherencia con los objetivos. Cada transformación responde a un objetivo:

- la homologación, a OE2;
- la selección poblacional, a OE3;
- el tratamiento de faltantes y atípicos y el denominador, a OE4;
- la conservación de la procedencia y de las columnas originales, a la trazabilidad que exige todo el proyecto.

10. Validación técnica y verificación del código

- **F1:** 6 pruebas de casos normales, límite y excepciones: CSV válido, archivo ausente, archivo vacío, columna territorial ausente, separación de nombres repetidos y clasificación de consumo. Todas aprobadas.
- **F2:** 40 pruebas automatizadas en 10 grupos, todas aprobadas y exportadas a `07_cen_validaciones_tecnicas.csv`:

Grupo	**Pruebas**	**Grupo**	**Pruebas**
Normalización	5	Integridad documental	4
Auditoría geográfica	4	Integridad territorial	4

Grupo	Pruebas	Grupo	Pruebas
Clasificación operacional	5	Conjunto prioritario	5
Conversión temporal	5	Calidad temporal	3
Control de excepciones	1	Consistencia causal	4

- **Comprobaciones en cada etapa:** F2 contiene 149 instrucciones `assert` que detienen la ejecución donde se origina un problema. Algunas comprueban que no se pierdan informes, que no se dupliquen vínculos, que las tablas cuadren y que el casting no cambie valores. Otras **fijan la evidencia de las decisiones**: si datos nuevos rompen el patrón de la D-05, el notebook avisa que hay que revisarla.
- **Evidencia conservada:** los notebooks se entregan **con sus salidas**: conteos antes y después, tablas y perfiles del conjunto final.

11. Notebook F1: definición y entorno

`F1/F1_Definición.ipynb` contiene:

- **Celdas narrativas:** problemática, pregunta, objetivos, alcance, metodología y referencias.
- **Verificación del entorno:** versión de Python, entorno virtual, 106 dependencias, commit y semilla.
- **Verificación estructural del consolidado:** reconocimiento inicial de los datos.
- **Seis pruebas iniciales.**
- **El mapa conceptual.**

Alcance respetado: F1 **no limpia, no imputa ni transforma**. Lee el CSV sin modificarlo y solo calcula resúmenes. El notebook corre completo con *Restart Kernel and Run All Cells*, con numeración de ejecución continua.

12. Notebook F2: exploración y preprocesamiento

`F2/F2_Exploracion_y_Preprocesamiento.ipynb` sigue el flujo que pide la guía, con una celda narrativa al inicio de cada etapa:

Etapa	Secciones
Entorno	§0
Obtención y carga	§1–§3
Exploración y calidad	§4
Limpieza y normalización	§5
Integración y homologación	§6.5–§6.7
Transformación	§6.8–§6.10
Caracterización	§6.11–§6.13
Validación	§6.14

Etapa	Secciones
Exportación	§6.15
Conclusiones	§6.16

El notebook corre completo, con numeración continua, y exporta el conjunto procesado a `data/processed/`, que es la entrada directa de F3.

13. Vinculación del mapa conceptual con el avance

El mapa conceptual de la Formativa 1 se corrigió con la retroalimentación docente (issues #8–#13):

- se agregó la pregunta analítica;
- se agregó la etapa de obtención de los datos;
- todo el texto quedó en 11 pt o más.

El mapa se genera desde F1 (§9). La tabla relaciona cada tipo de elemento del mapa con su implementación:

Elemento del mapa	Tipo	Estado	Evidencia
Git y GitHub	Herramienta	Implementado	Historial con commits por integrante, PR #2–#6 y #14, issues #8–#13
Python `src/`, Jupyter, pandas y NumPy	Herramienta	Implementado	`src/` (3 módulos), F1 y F2
Pruebas `assert`	Herramienta	Implementado	6 pruebas en F1, 40 en F2 y 149 `assert`
matplotlib	Herramienta	Parcial	Mapa y figuras exploratorias; visualizaciones finales en F4
① Pregunta	Proceso	Implementado	F1 §3
② Obtención	Proceso	Implementado	`src/descargar_cen.py`, `docs/descargas_cen.csv`
③ Depuración	Proceso	Implementado	F2 §4–§5
④ Homologación	Proceso	Implementado	F2 §6.5–§6.7, `data/reference/`
⑤ Caracterizar	Proceso	Parcial	F2 §6.11–§6.13; indicadores finales en F3
⑥ Comunicar	Proceso	Parcial	Este informe; comunicación de resultados en F4

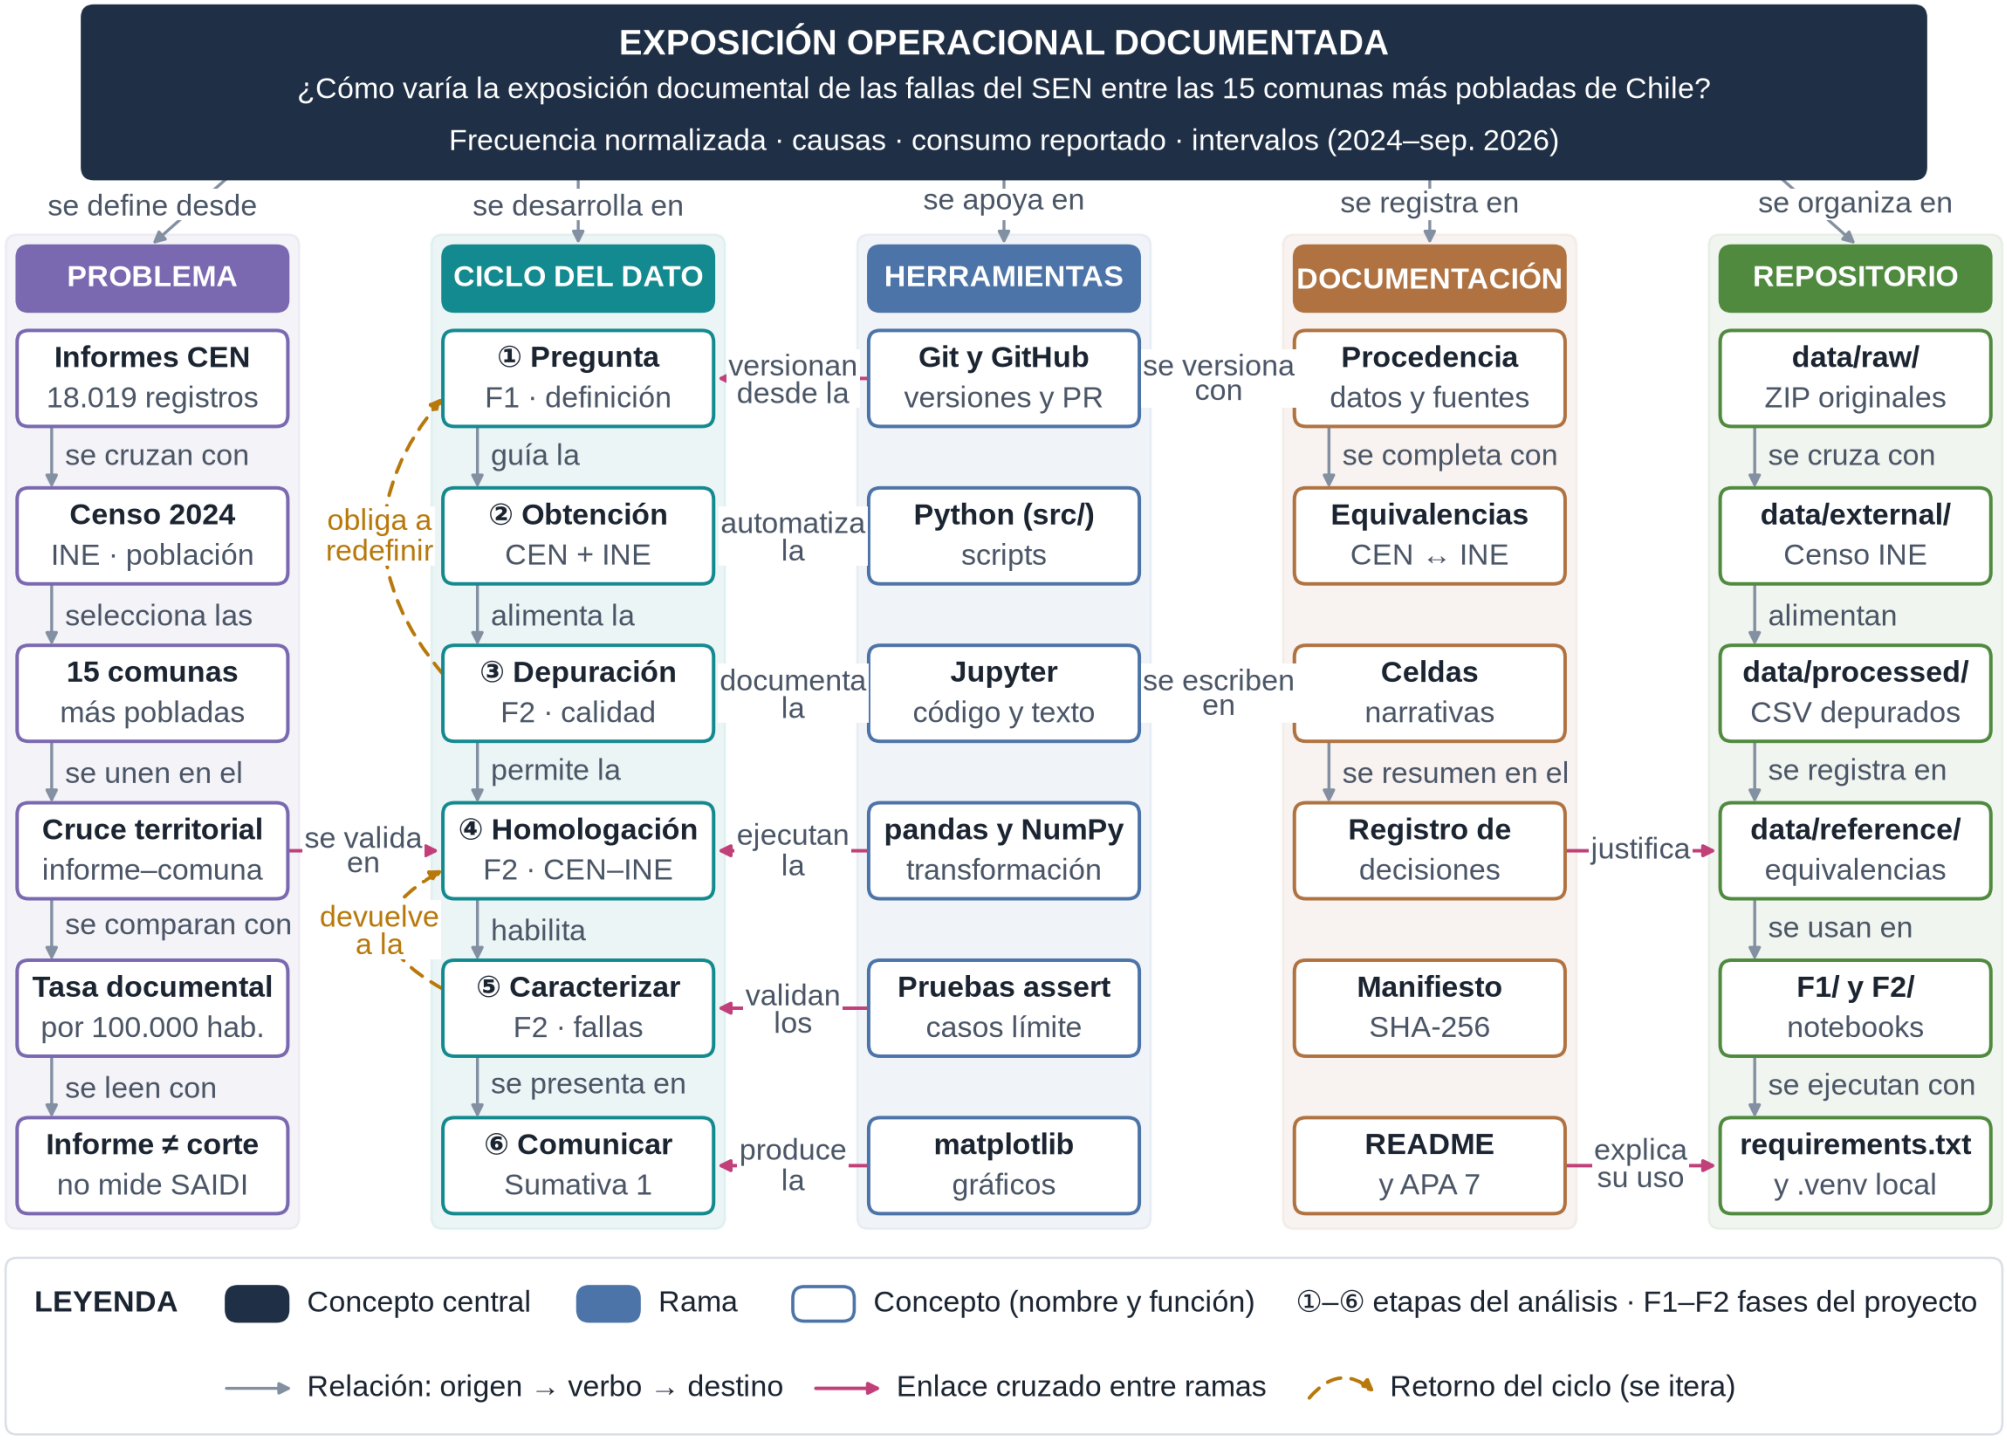
Elemento del mapa	Tipo	Estado	Evidencia
Retornos del ciclo	Flujo reproducible	Implementado	La depuración obligó a redefinir la pregunta (NYC 311 → CEN); la revisión de asociaciones pendientes devolvió a la homologación (equivalencias y validación multirregional, F2 §6.4.4–§6.4.5)
`requirements.txt`, `.venv` y manifiesto SHA-256	Flujo reproducible	Implementado	`src/trazabilidad.py`, `docs/verificacion_entorno.md`
Registro de decisiones y equivalencias	Decisión técnica	Implementado	`docs/decisiones.md` (D-01 a D-09)
Tasa documental por 100.000 habitantes	Decisión técnica	Propuesto	F2 §6.13.7 (D-06); cálculo final en F3
`data/raw`, `external`, `reference` y `processed`	Organización del repositorio	Implementado	Carpetas con su propio README
F1/ y F2/	Estructura del notebook	Implementado	Un notebook por fase, con celdas narrativas por etapa

Justificación. Lo implementado coincide con lo que el mapa proyectaba para F1 y F2: herramientas, obtención, depuración, homologación y un flujo reproducible. La validación de F2 lo comprueba. Lo pendiente (⑤ caracterizar, ⑥ comunicar y la tasa documental) sigue siendo pertinente, porque responde directamente a OE4 y OE5, que el plan asigna a F3 y F4. Los dos retornos del mapa ocurrieron de verdad: el conjunto inicial se reemplazó tras la exploración, y la homologación se ajustó después de revisar las asociaciones pendientes.

Figura 1 (página siguiente). Mapa conceptual del proyecto, generado por F1 §9. Se reproduce a tamaño real, en carta horizontal, para conservar su texto en 11 pt.

MAPA CONCEPTUAL · ANÁLISIS TERRITORIAL DE FALLAS DEL SEN · GRUPO 7

FUENTES: informes del CEN (ene. 2024–sep. 2026) · Censo 2024 del INE



LEYENDA

Concepto central · Rama · Concepto (nombre y función) · ①–⑥ etapas del análisis · F1–F2 fases del proyecto

Relación: origen → verbo → destino · Enlace cruzado entre ramas · Retorno del ciclo (se itera)

14. Referencias

Barker, M., Chue Hong, N. P., Katz, D. S., Lamprecht, A.-L., Martinez-Ortiz, C., Psomopoulos, F., Harrow, J., Castro, L. J. G., Gruenpeter, M., Martinez, P. A., & Honeyman, T. (2022). Introducing the FAIR principles for research software. *Scientific Data, 9*, artículo 622. https://doi.org/10.1038/s41597-022-01710-x

Chacon, S., & Straub, B. (2014). *Pro Git* (2.ª ed.). Apress. https://git-scm.com/book/es/v2

Comisión Nacional de Energía. (2024). *Norma técnica de calidad de servicio para sistemas de distribución*. https://www.cne.cl/normativas/electrica/normas-tecnicas/ntcsdx2024/

Coordinador Eléctrico Nacional. (s. f.). *Desconexiones e intervenciones / informes de falla / limitaciones* [Conjunto de datos]. https://www.coordinador.cl/operacion/graficos/desconexiones-e-intervenciones/

Instituto Nacional de Estadísticas. (2025). *Resultados del Censo de Población y Vivienda 2024*. https://censo2024.ine.gob.cl/resultados/

pandas development team. (s. f.-a). *pandas.to_datetime*. *pandas documentation*. https://pandas.pydata.org/docs/reference/api/pandas.to_datetime.html

pandas development team. (s. f.-b). *Working with missing data*. *pandas documentation*. https://pandas.pydata.org/docs/user_guide/missing_data.html

Python Software Foundation. (s. f.). *venv — Creation of virtual environments*. *Python 3.13 documentation*. https://docs.python.org/3.13/library/venv.html

Salinas, O. (2026a). *Limpieza y transformación de datos tabulares con Pandas* [Apunte]. Universidad Andrés Bello.

Salinas, O. (2026b). *Estructura profesional de un proyecto Python* [Apunte]. Universidad Andrés Bello.

Salinas, O. (2026c). *Tipos, variables, booleanos, condicionales, ciclos, funciones, módulos y excepciones en Python* [Apunte]. Universidad Andrés Bello.

Superintendencia de Electricidad y Combustibles. (s. f.). *Interrupciones eléctricas – SAIDI*. https://www.sec.cl/informe-sec-saidi/

Wilson, G., Bryan, J., Cranston, K., Kitzes, J., Nederbragt, L., & Teal, T. K. (2017). Good enough practices in scientific computing. *PLOS Computational Biology, 13*(6), e1005510. https://doi.org/10.1371/journal.pcbi.1005510

Anexo A. Declaración de uso de inteligencia artificial

El equipo usó un asistente de inteligencia artificial generativa (Claude, de Anthropic, mediante Claude Code) como apoyo para:

- revisar código;
- proponer las correcciones del feedback docente;
- redactar documentación y mensajes de commit;
- generar el mapa conceptual;
- estructurar este informe.

Todas las cifras provienen de la ejecución de los notebooks y de los archivos del repositorio. El equipo revisó el contenido, tomó las decisiones metodológicas (registradas en `docs/decisiones.md`) y es responsable de cada afirmación. Cada integrante debe poder explicar el código y las decisiones del proyecto.